MODÉLISATION D'EPIDÉMIES

25 mai 2025

Kaoutar Bouaachra & Abdelbar Ghassoub
Encadré par: Arvind Singh

1
REMERCIEMENTS

Nous tenons à exprimer notre profonde gratitude à Madame Gersende Fort, responsable du cours MODAL, pour son encadrement et son enseignement théorique et numérique, qui nous a permis de réaliser et de présenter ce travail.

Nos remerciements vont particulièrement à Arvind Singh, dont les remarques avisées, les conseils et l'encadrement rigoureux nous ont guidés tout au long de notre projet.

Nous remercions également l'équipe scientifique qui nous a encadrés dans ce cours MODAL :

- Orso Forghieri
- Charles-Albert Lehalle
- Tony Lelièvre
- Clément Rey

TABLE DES MATIÈRES

1 Remerciements

2 Introduction
2.1 Motivations et introduction . . . . . .
2.2 Objectif du projet . . . . . .

3 Modélisation
3.1 Modélisation déterministe : le modèle SIR classique . . . . . .
3.1.1 Mise en equation . . . . . .
3.1.2 Simulation numérique . . . . . .
3.2 Modèle SIR avec vaccination . . . . . .
3.3 Modélisation stochastique : chaînes de Markov . . . . . .
3.4 Comparaison entre modèle stochastique et déterministe . . . . . .

4 Estimation de la probabilité que $R_\infty > K$
4.1 Formulation du problème . . . . . .
4.2 Méthode de Monte Carlo standard . . . . . .
4.3 Échantillonnage préférentiel (Importance Sampling) . . . . . .
4.4 Méthode de splitting . . . . . .
4.5 Analyse comparative des méthodes . . . . . .

5 Étude des évenement rares : Estimation de la probabilité $P(I_{\mathbf{max}} > K)$
5.1 Comparaison des méthodes . . . . . .
5.1.1 probabilité de l'ordre de 10^{-1} . . . . . .
5.1.2 probabilité de l'ordre de 10^{-5} . . . . . .

6 Extension du modèle SIR : le modèle SEIR
6.1 Compartiments du modèle SEIR . . . . . .
6.2 Modèle déterministe . . . . . .
6.3 Modèle stochastique . . . . . .
6.4 Intérêt de l'ajout du compartiment E . . . . . .

7 Graphes
7.1 Epidémie sur $\mathbf{Z}$ . . . . . .
7.1.1 La loi théorique du nombres d'infectés . . . . . .
7.1.2 La loi théorique de la durée de l'épidemie . . . . . .
7.1.3 Comparaison entre les lois théoriques et la simulation numérique . . . . . .
7.2 Tirage sous la loi de la durée de lépidémie . . . . . .
7.2.1 Simulation par inversion de la fonction de répartition . . . . . .
7.2.2 Simulation par la méthode de rejet . . . . . .
7.2.3 Métropolis Hasting pour la loi conditionnelle de T sachant $T > K$ . . . . . .
7.3 Estimation des probabilités des événements rares . . . . . .
7.4 Epidémie sur un arbre régulier . . . . . .

8 Conclusion et Perspectives

2
INTRODUCTION

2.1 Motivations et introduction

Dans un monde interconnecté où les épidémies peuvent se propager rapidement à grande échelle, la compréhension fine des mécanismes de transmission est devenue cruciale. Au-delà de leur intérêt théorique, les modèles épidémiologiques sont aujourd'hui au cœur des décisions de santé publique, en guidant la mise en œuvre de politiques de prévention, de confinement ou de vaccination. Ils contribuent également à une meilleure allocation des ressources médicales et à l'élaboration de scénarios d'intervention adaptés à différents contextes.

C'est ce contexte qui nous a motivés à choisir un projet autour de la modélisation des épidémies. Ce sujet nous permet de traiter des questions concrètes et actuelles, tout en mettant en œuvre des outils mathématiques dans le cadre du Modal. À travers des simulations, notre objectif est de mieux comprendre comment une épidémie peut se propager et d'identifier les risques liés à certains scénarios critiques, comme celui d'une épidémie de grande ampleur.

2.2 Objectif du projet

L'objectif principal de ce projet est d'étudier et de comparer différentes méthodes de simulation pour l'analyse des événements rares dans les modèles épidémiques. Plus spécifiquement, nous nous intéressons à :

- La modélisation classique SIR et ses extensions (SEIR, modèles avec vaccination)
- L'estimation de probabilités d'événements rares comme $P(R_\infty > K)$ ou $P(I_{\max} > K)$
- La comparaison des méthodes de Monte Carlo standard avec des techniques avancées (échantillonnage préférentiel, Adaptative splitting)
- L'étude des épidémies sur des structures de graphes (Z, arbres réguliers)

3
MODÉLISATION

3.1 Modélisation déterministe : le modèle SIR classique

3.1.1 • Mise en equation

Le modèle SIR est un modèle compartimental utilisé en épidémiologie pour décrire la propagation d'une maladie infectieuse dans une population fermée. Il divise la population en trois compartiments :

— $S(t)$: le nombre d'individus **susceptibles** d'être infectés à l'instant t ;

— $I(t)$: le nombre d'individus **infectés et infectieux** à l'instant t ;

— $R(t)$: le nombre d'individus **retirés** (guéris ou morts, donc immunisés ou plus infectieux) à l'instant t.

Le modèle repose sur les équations différentielles suivantes :

$$\begin{cases} \dfrac{dS}{dt} = -\beta S(t)I(t), \\[2ex] \dfrac{dI}{dt} = \beta S(t)I(t) - \gamma I(t), \\[2ex] \dfrac{dR}{dt} = \gamma I(t), \end{cases}$$

où :

— $\beta > 0$ est le taux de transmission (contact infectieux entre S et I) ;

— $\gamma > 0$ est le taux de guérison (ou de retrait).

Le modèle suppose que la taille totale de la population $N = S(t) + I(t) + R(t)$ reste constante (pas de naissance ni de décès autre que ceux dus à la maladie). Le comportement de l'épidémie dépend fortement du nombre de reproduction de base $R_0 = \beta/\gamma$. Si $R_0 > 1$, une épidémie peut se produire ; sinon, la maladie s'éteint rapidement.

3.1.2 • Simulation numérique

$$\begin{cases} \frac{dS}{dt} = -\beta SI, \\[2ex] \frac{dI}{dt} = \beta SI - \gamma I, \\[2ex] \frac{dR}{dt} = \gamma I, \end{cases}$$

la méthode que nous avons utilisé pour la simulation numérique consiste à discrétiser le temps avec un pas $\Delta t > 0$, et à approximer les dérivées par :

$$\frac{dS}{dt} \approx \frac{S_{n+1} - S_n}{\Delta t}, \quad \frac{dI}{dt} \approx \frac{I_{n+1} - I_n}{\Delta t}, \quad \frac{dR}{dt} \approx \frac{R_{n+1} - R_n}{\Delta t}.$$

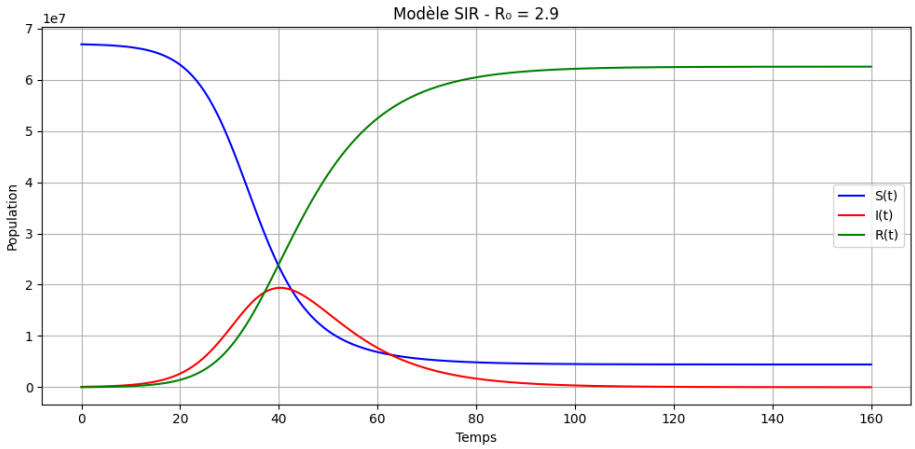

FIGURE 1 – Simulation SIR deterministe

On obtient alors les formules d'itération suivantes :

$$\begin{cases} S_{n+1} = S_n - \Delta t \cdot \beta S_n I_n, \\ \\ I_{n+1} = I_n + \Delta t \cdot (\beta S_n I_n - \gamma I_n), \\ \\ R_{n+1} = R_n + \Delta t \cdot \gamma I_n. \end{cases}$$

Pour simuler une dynamique épidémique réaliste, nous avons choisi des valeurs de paramètres inspirées des premières phases de la pandémie de COVID-19 en France, en particulier la première vague de mars-avril 2020. Selon les estimations de l'Institut Pasteur, le nombre de reproduction de base $\mathcal{R}_0$ était de l'ordre de 2,9, et la durée moyenne d'infection était d'environ 10 jours. En utilisant la relation $\mathcal{R}_0 = \beta/\gamma$, et en posant $\gamma = 0{,}1$ (correspondant à une période infectieuse moyenne de 10 jours), on en déduit $\beta = 0{,}29$.

Ces valeurs ont été utilisées dans notre première simulation numérique pour observer l'évolution théorique des proportions de personnes susceptibles, infectées et guéries au cours du temps.

Dans cette simulation, la population totale est fixée à $N = 67\,000\,000$ (population française estimée). Les conditions initiales sont les suivantes : $S_0 = 66\,933\,000$, $I_0 = 67\,000$, $R_0 = 0$, ce qui correspond à une situation où environ 0,1 % de la population est initialement infectée. Fig.(1)

- L'INFLUENCE DE R_0

Les figures 2 et 3 illustrent le portrait de phase du système différentiel réduit à deux dimensions dans le domaine admissible $P = \{(s,i) \in [0,1]^2 \mid s + i \leq 1\}$, avec $s = \frac{S}{N}$ et $i = \frac{I}{N}$ pour les cas $R_0 > 1$ et $R_0 < 1$ respectivement. Ces figures permettent de visualiser l'influence du paramètre R_0 sur la dynamique épidémique.

La nullecline définie par $\dot{i} = 0$, soit $s = \frac{1}{R_0}$, est également représentée. Elle joue un rôle crucial dans la dynamique du système : elle sépare les zones où la population infectée croît ($\dot{i} > 0$) de celles où elle décroît ($\dot{i} < 0$).

— Pour $R_0 > 1$, la nullecline $s = 1/R_0$ est à l'intérieur du domaine P, et le point $(1,0)$ devient un point d'équilibre *instable*. Les trajectoires s'en éloignent, traduisant l'apparition d'une épidémie.

— Pour $R_0 < 1$, la nullecline sort du domaine admissible, ce qui implique $\dot{i} < 0$ partout dans P. Le point $(1, 0)$ devient alors un point d'équilibre *stable*, vers lequel toutes les trajectoires convergent : aucune épidémie ne se déclenche.

Ce comportement peut être confirmé par une analyse linéaire au voisinage du point $(1, 0)$. La matrice jacobienne évaluée en ce point est donnée par :

$$DJ(1,0) = \begin{pmatrix} 0 & -\beta \\ 0 & \beta - \gamma \end{pmatrix}$$

Elle possède les valeurs propres 0 et $\lambda = \beta - \gamma = \gamma(R_0 - 1)$. Ainsi :

— si $R_0 > 1$, alors $\lambda > 0$, l'état $(1, 0)$ est instable, ce qui correspond à une dinamique épidémique croissante ;

— si $R_0 < 1$, alors $\lambda < 0$, l'état $(1, 0)$ est stable et l'épidémie s'éteint.

Le paramètre R_0 apparaît donc comme un paramètre qui modifie qualitativement la nature du point d'équilibre $(1, 0)$. Ce changement structurel du portrait de phase est au cœur de la compréhension de la propagation ou non d'une épidémie dans la population.

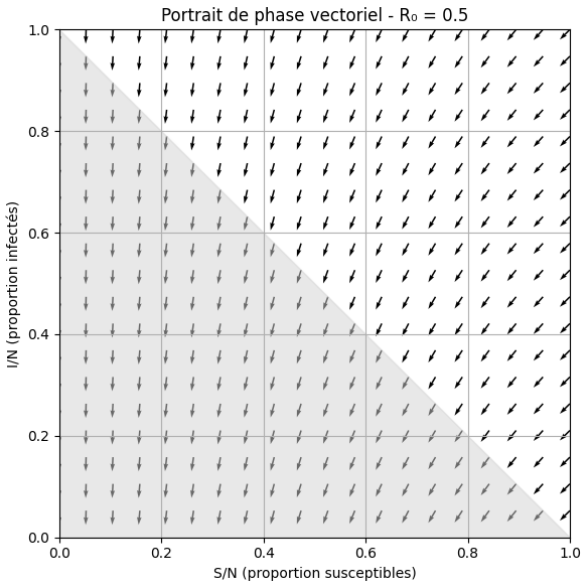

FIGURE 2 – Première figure

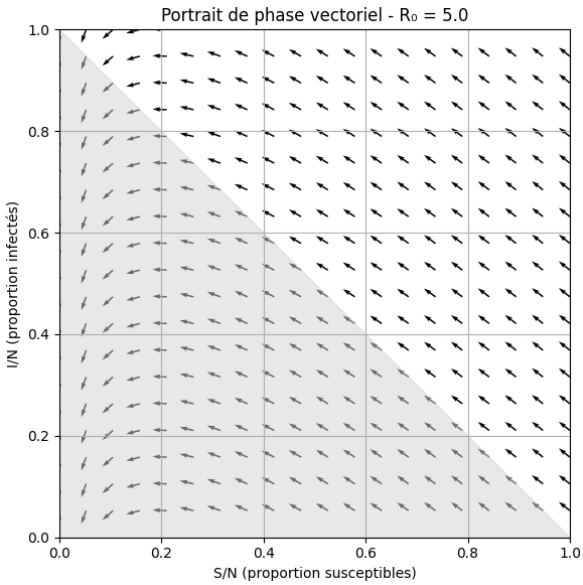

FIGURE 3 – Deuxième figure

- INFLUENCE DE $R_0 \cdot \frac{S_0}{N}$

En faisant varier les paramètres du problème, on note l'apparition d'un autre paramètre critique $R_0 \cdot \frac{S_0}{N}$ qui détermine la forme de l'évolution du nombre d'infectés durant l'épidémie. 4

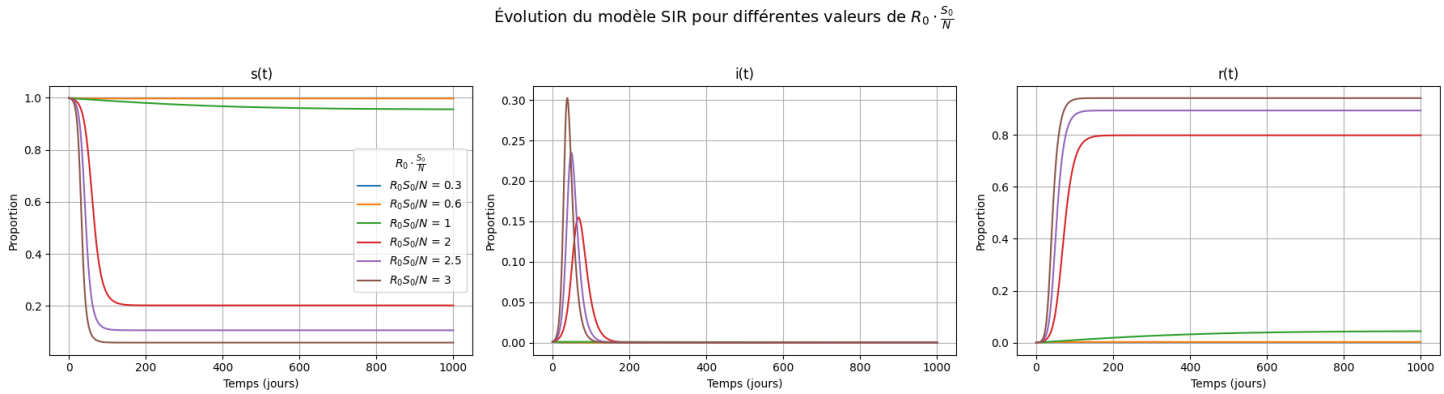

FIGURE 4 – Evolution du modèle SIR en fonction du paramètre $R_{ref} = R_0 \cdot \frac{S_0}{N}$

- LE PIC ÉPIDÉMIQUE THÉORIQUE

Du point de vue de santé publique, il est utile de connaître le nombre maximal d'individus infectés lors d'une épidémie. Cette recherche peut se faire en examinant les deux premières équations du système :

$$\frac{dI}{dt} = \frac{\beta}{N} S(t)I(t) - \gamma I(t) = \left(\frac{\beta}{N} S(t) - \gamma\right) I(t). \tag{1}$$

On observe que $I(t)$ est croissante lorsque $S(t) > \frac{\gamma N}{\beta}$ et décroissante lorsque $S(t) < \frac{\gamma N}{\beta}$. Le pic épidémique est donc atteint lorsque :

$$S(t) = \frac{\gamma N}{\beta}. \tag{2}$$

À partir du système :

$$\frac{dI}{dt} = \left(\frac{\beta}{N} S(t) - \gamma\right) I(t),$$

On combine ensuite les équations du système pour obtenir une relation intégrale :

$$\frac{dI}{dt} = \left(\frac{\beta}{N} S(t) - \gamma\right) I(t) = \left(\frac{\gamma N}{\beta S(t)} - 1\right) \frac{dS}{dt}.$$

On intègre ensuite cette relation dans le temps, en exploitant la linéarité de l'intégrale :

$$\int_0^t \frac{dI}{du}\, du = \frac{\gamma N}{\beta} \int_0^t \frac{dS(u)}{S(u)}\, du - \int_0^t dS(u).$$

Ce qui donne, après intégration :

$$I(t) - I(0) = \frac{\gamma N}{\beta} \ln\left(\frac{S(t)}{S_0}\right) + S_0 - S(t).$$

On en déduit :

$$S(t) + I(t) = \frac{\gamma N}{\beta} \ln\left(\frac{S(t)}{S_0}\right) + N.$$

Puisqu'on connaît $S(t)$ au moment du pic, on peut injecter cette valeur pour obtenir la formule du pic $I_{\max}$.

Dans ce cas, on peut exprimer $I_{\max}$, le nombre maximal d'infectés, comme :

$$I_{\max} = N\left[1 - \frac{\gamma}{\beta} + \frac{\gamma}{\beta}\ln\left(\frac{\gamma N}{\beta S_0}\right)\right]. \tag{3}$$

- **Le nombre total d'individus infectés et immunisés théoriques**

La taille finale de l'épidémie est le nombre total d'individus ayant été infectés, notée $R_\infty = N - S_\infty$. En partant de :

$$\frac{dS}{dt} = -\frac{\beta}{N}S(t)I(t),$$

et après intégration, on obtient l'équation implicite :

$$S_\infty = S_0 \exp\left[\frac{\beta}{\gamma}\left(\frac{S_\infty}{N} - 1\right)\right],$$

ou, avec $R_0 = \frac{\beta}{\gamma}$,

$$S_\infty = S_0 \exp\left[R_0\left(\frac{S_\infty}{N} - 1\right)\right].$$

On peut également écrire la taille finale des cas infectés comme :

$$R_\infty = N\left[1 - \exp\left(-R_0\frac{R_\infty}{N}\right)\right].$$

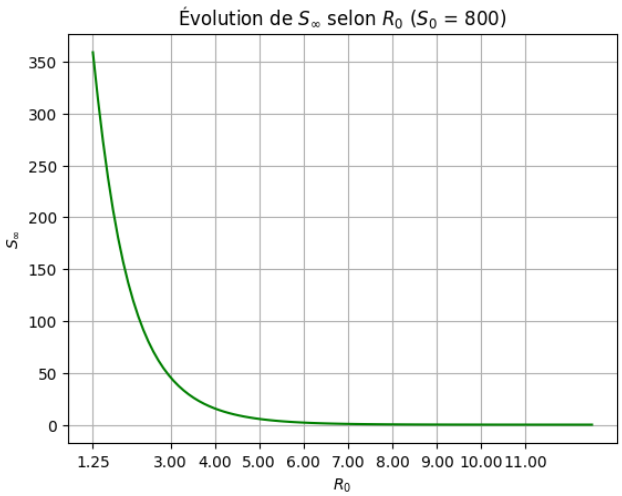

Figure 5 – Valeur finale S_∞ selon R_0

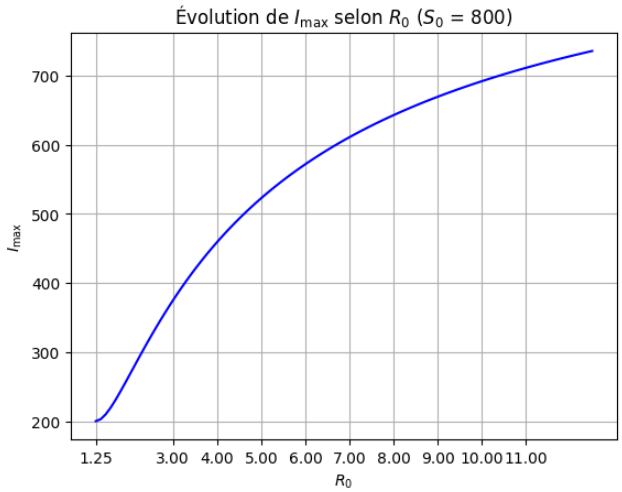

Figure 6 – Évolution de $I_{\max}$ en fonction de R_0

3.2 Modèle SIR avec vaccination

Modèle Mathématique

Nous considérons ici un modèle SIR enrichi par une fonction de contrôle $u(t)$, représentant une stratégie de vaccination ou d'intervention. Le système d'équations devient :

$$\begin{cases} \dot{S}(t) = -\alpha S(t)I(t) + u(t) \\ \dot{I}(t) = \alpha S(t)I(t) - \beta I(t) - u(t) \\ \dot{R}(t) = \beta I(t) \end{cases}$$

avec les paramètres :

- $\alpha > 0$: taux d'infection
- $\beta > 0$: taux de guérison
- $u(t) \in [0, m]$: contrôle (taux de vaccination ou isolement)

Problème d'Optimisation

On cherche à déterminer la stratégie optimale $u(t)$ qui minimise une fonction de coût combinant le nombre d'infectés en fin d'épidémie et le coût du contrôle (vaccination ou isolement) appliqué :

$$J(u) = \gamma I(T) + \frac{1}{2}\int_0^T u(t)^2\, dt$$

où $\gamma > 0$ pondère la priorité entre la minimisation des infections finales et le coût du contrôle. On suppose que $u \in L^2([0, T]; [0, m])$.

Analyse Préliminaire

Existence et unicité. Sous des conditions raisonnables (continuité de $f(x, u)$, bornes sur $u(t)$), le système admet une solution unique pour tout $t \in [0, T]$.

Conditions initiales.

$$S(0) = S_0 \geq 0, \quad I(0) = I_0 \geq 0, \quad R(0) = R_0 \geq 0, \quad S_0 + I_0 + R_0 = N$$

Méthode du Contrôle Optimal

- Formulation vectorielle

Soit $x(t) = \begin{pmatrix} S(t) \\ I(t) \\ R(t) \end{pmatrix}$, on définit :

$$\dot{x}(t) = f(x, u) = \begin{pmatrix} -\alpha SI + u \\ \alpha SI - \beta I - u \\ \beta I \end{pmatrix}$$

La matrice Jacobienne de f par rapport à x est :

$$\frac{\partial f}{\partial x}(x, u) = \begin{pmatrix} -\alpha I & -\alpha S & 0 \\ \alpha I & \alpha S - \beta & 0 \\ 0 & \beta & 0 \end{pmatrix}$$

- **Équation Adjointe**

  L'adjoint $p(t) = \begin{pmatrix} p_S(t) \\ p_I(t) \\ p_R(t) \end{pmatrix}$ satisfait :

$$\dot{p}(t) = -\left(\frac{\partial f}{\partial x}(x,u)\right)^T p(t), \quad \text{avec } p(T) = \begin{pmatrix} 0 \\ \gamma \\ 0 \end{pmatrix}$$

- **Hamiltonien**

  On définit l'Hamiltonien du système :

$$H(x,p,u) = p_S(-\alpha SI + u) + p_I(\alpha SI - \beta I - u) + p_R \beta I + \frac{1}{2}u^2$$

- **Commande optimale**

  En minimisant le Hamiltonien par rapport à u, on obtient :

$$u(t) = \begin{cases} 0 & \text{si } p_I(t) - p_S(t) \leq 0 \\ \min(m,\, p_I(t) - p_S(t)) & \text{sinon} \end{cases}$$

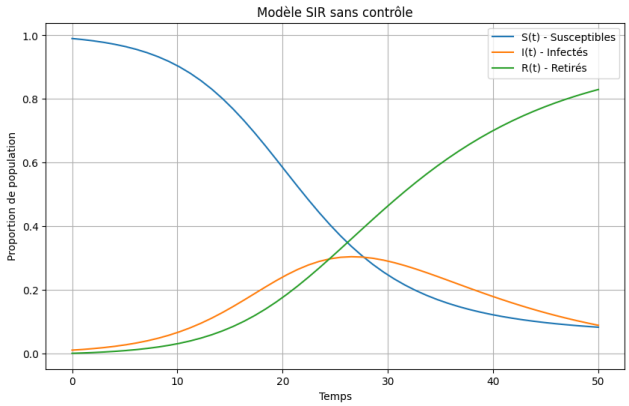

Figure 7 – Sans contrôle

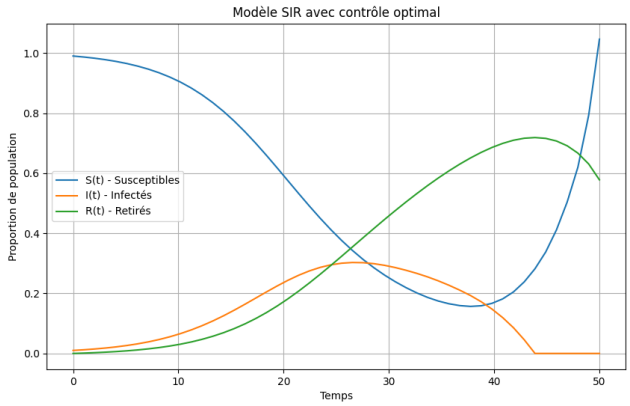

Figure 8 – Avec contrôle

Remarque : vers la fin quand I s'annule, la maximisation se penche alors sur le contrôle et c'est pour cela que $u(t)$ diverge exponentiellement après T=43, ceci justifie aussi le comportement de S et R après T=43.

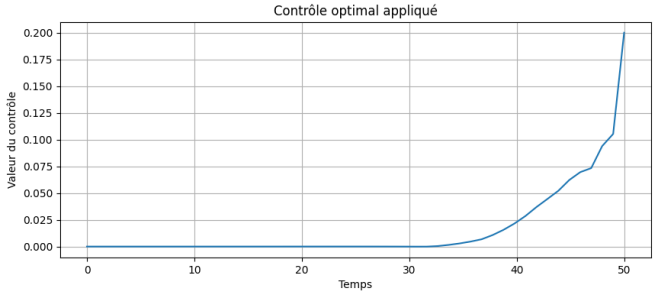

FIGURE 9 – Évolution du contrôle avec le temps

- CONCLUSION

Ce type de stratégie de contrôle optimal permet de trouver un compromis entre deux objectifs principaux :

— Accélérer l'extinction ; par exemple, dans notre cas, l'épidémie s'éteint à $T = 43$ avec contrôle, contre $T = 50$ sans contrôle.

— Minimiser le coût associé à la mise en œuvre de la stratégie de contrôle ($u(t)$).

3.3 MODÉLISATION STOCHASTIQUE : CHAÎNES DE MARKOV

Revenons maintenant à notre modèle SIR de base, sans contrôle, que nous avions initialement considéré avant l'introduction de la stratégie de vaccination optimale. Ce modèle déterministe est donné par le système d'équations différentielles suivant :

$$\begin{cases} \dot{S}(t) = -\dfrac{\beta S(t)I(t)}{N} \\ \dot{I}(t) = \dfrac{\beta S(t)I(t)}{N} - \gamma I(t) \\ \dot{R}(t) = \gamma I(t) \end{cases}$$

Pour tenir compte de l'incertitude inhérente aux dynamiques épidémiques, notamment dans les populations de taille finie, on introduit une version stochastique du modèle, formulée comme une chaîne de Markov à temps continu et à espace d'états discret. Le processus $(S(t), I(t), R(t))$ évolue selon les transitions suivantes :

$$(S, I, R) \mapsto \begin{cases} (S-1, I+1, R) & \text{à taux } \dfrac{\beta SI}{N} \\ (S, I-1, R+1) & \text{à taux } \gamma I \end{cases} \quad \text{où le processus s'arrête lorsque } I(t) = 0.$$

Chacune de ces transitions est associée à une **horloge exponentielle** de durée aléatoire, représentant le temps avant que l'événement se produise.

Le temps jusqu'au prochain événement est tiré selon une loi exponentielle de paramètre égal à la somme des deux taux :

$$\text{Taux total} = \beta \frac{SI}{N} + \gamma I.$$

Le type d'événement est ensuite déterminé de manière probabiliste :

$$\mathbb{P}(\text{infection}) = \frac{\beta SI/N}{\beta SI/N + \gamma I}, \quad \mathbb{P}(\text{guérison}) = \frac{\gamma I}{\beta SI/N + \gamma I}.$$

Ce mécanisme repose sur l'idée que chaque individu infectieux est muni d'une horloge de guérison exponentielle indépendante de paramètre γ, et que chaque paire (S, I) forme une horloge d'infection de paramètre $\beta/N/$ La compétition entre ces horloges constitue la base de la simulation des dynamiques stochastiques de l'épidémie. Nous présentons ici deux méthodes différentes pour simuler ce processus.

Première méthode de simulation

À partir d'un état $(S(t), I(t), R(t))$, pour déterminer l'état suivant dans un processus SIR stochastique, on peut simuler deux variables aléatoires indépendantes :

— $T_0 \sim \mathcal{E}\left(\frac{\beta SI}{N}\right)$: temps avant une infection,

— $T_1 \sim \mathcal{E}(\gamma I)$: temps avant une guérison.

La chaîne reste alors dans l'état courant pendant un temps

$$T = \min(T_0, T_1)$$

et effectue une transition déterminée par la comparaison $1(T_1 > T_0)$, c'est-à-dire :

— si $T_0 < T_1$, une infection se produit : $(S - 1, I + 1, R)$,

— sinon, une guérison : $(S, I - 1, R + 1)$.

Deuxième méthode de simulation

On peut utiliser une deuxième methode pour simuler notre chaine de markov, qui sera justifiée et prouvée par la suite ;

— on simule un unique temps $T \sim \mathcal{E}\left(\frac{\beta SI}{N} + \gamma I\right)$,

— puis on simule une variable de Bernoulli $S \sim \mathcal{B}\left(\frac{\frac{\beta S \cdot I}{N}}{\frac{\beta S \cdot I}{N} + \gamma \cdot I}\right)$,

— si $S = 1$, on effectue une infection, sinon une guérison.

Cette méthode, équivalente à la précédente, présente un avantage conceptuel important : il n'est pas nécessaire de connaître les instants exacts des sauts pour déterminer des propriétés globales du système (par exemple l'état final). Ainsi, l'ordre exact des événements dans le temps peut être ignoré.

Démonstration

Soient $T_0 \sim \mathcal{E}(\lambda)$ et $T_1 \sim \mathcal{E}(\gamma)$, indépendantes. Alors :

— $T = \min(T_0, T_1) \sim \mathcal{E}(\lambda + \gamma)$,

— $S = 1(T_1 > T_0) \sim \mathcal{B}\left(\frac{\lambda}{\lambda + \gamma}\right)$,

— T et S sont indépendants.

Ona

$$\begin{aligned}
\mathbb{E}[1(T>\alpha)\cdot 1(S=1)] &=^{\infty}{}^{\infty}1(\min(s,t)>\alpha)1(t>s)\lambda e^{-\lambda s}\gamma e^{-\gamma t}dsdt \\
&= \int_{\alpha}^{\infty} \lambda e^{-\lambda s}\left(\int_{s}^{\infty}\gamma e^{-\gamma t}dt\right)ds \\
&= \int_{\alpha}^{\infty} \lambda e^{-\lambda s}e^{-\gamma s}ds \\
&= \int_{\alpha}^{\infty} \lambda e^{-(\lambda+\gamma)s}ds = \frac{\lambda}{\lambda+\gamma}e^{-(\lambda+\gamma)\alpha}
\end{aligned}$$

Ainsi on a prouvé que

$$\mathbb{E}[1(T>\alpha)\cdot 1(S=1)] = \mathbb{E}[1(T>\alpha)]\cdot\mathbb{P}(S=1) = \frac{\lambda}{\lambda+\gamma}e^{-(\lambda+\gamma)\alpha}$$

Ce qui montre que T et S sont indépendants. Dans nos simulations nous avons fait le choix d'utiliser la deuxième méthode de modélisation :

- Résultats de simulation

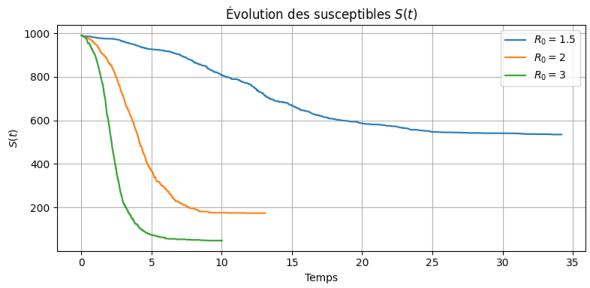

Evolution des susceptibles S(t)

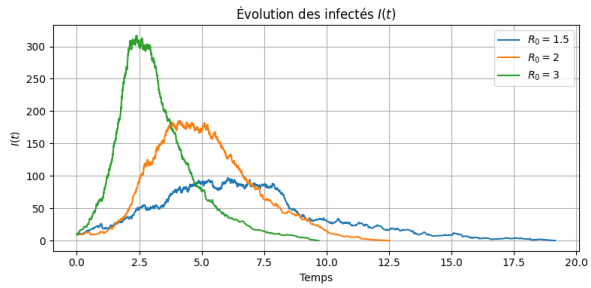

Evolution des infectés I(t)

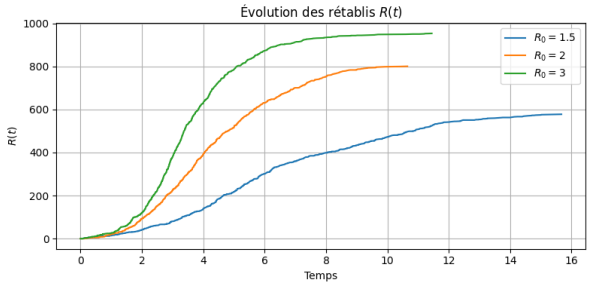

Evolution des rétablis R(t)

Figure 10 – Evolution du processus stochastique pour différentes valeurs de R_0

3.4 Comparaison entre modèle stochastique et déterministe

Illustration de la Loi des Grands Nombres

Nous avons simulé le modèle épidémique pour différentes tailles de population N croissantes, ici $N = 10, 50, 100, 10\,000$. Pour chaque taille, des simulations stochastiques ont été réalisées et comparées à la solution déterministe.

La figure 11 montre les proportions de susceptibles, infectés et retirés au cours du temps. On observe que les trajectoires stochastiques $\frac{S_N(t)}{N}$, $\frac{I_N(t)}{N}$, $\frac{R_N(t)}{N}$ convergent vers la solution déterministe correspondante à mesure que N augmente. Cette convergence illustre la Loi des Grands Nombres, qui garantit que la moyenne empirique tend vers sa valeur théorique lorsque la population devient grande.

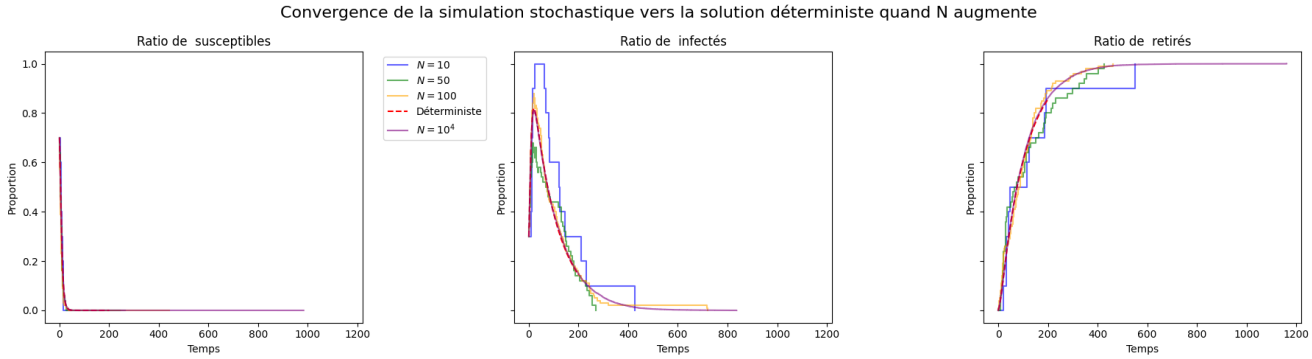

FIGURE 11 – Convergence des simulations stochastiques vers la solution déterministe pour différentes tailles de population N.

ILLUSTRATION DU TCL

L'objectif de cette partie est d'illustrer le lien entre les modèles stochastique et déterministe à travers le Théorème Central Limite (TCL). En effet, lorsque la taille de la population N devient grande, les fluctuations normalisées des processus stochastiques autour de leur comportement déterministe sont censées converger en loi vers une distribution normale.

Pour visualiser cet écart, nous traçons à un instant donné t les quantités

$$\sqrt{N}\Big(S_N(t) - S(t)\Big) \quad \text{et} \quad \sqrt{N}\Big(I_N(t) - I(t)\Big),$$

où $S_N(t)$ et $I_N(t)$ représentent les proportions stochastiques de susceptibles et d'infectés dans une population de taille N, tandis que $S(t)$ et $I(t)$ sont les solutions déterministes correspondantes. Selon le TCL, ces écarts devraient approcher une distribution normale lorsque $N \to \infty$, ce que nous vérifions numériquement par cette analyse.

Voici les histogrammes des écarts pour les infectés des deux solutions à un instant donné (t=10). On observe clairement que la distribution de ces écarts tend vers une forme gaussienne lorsque la taille de la population N augmente.

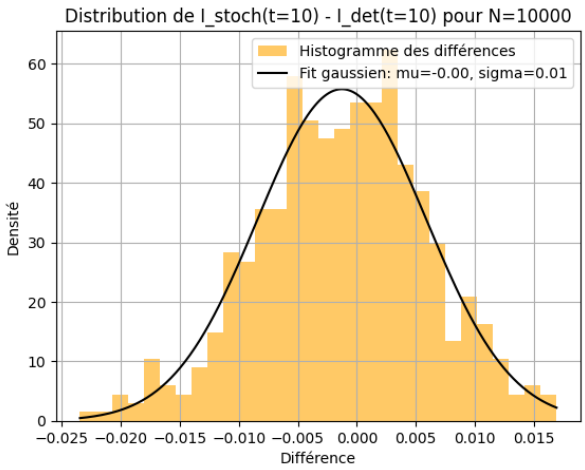

FIGURE 12 – Ecart entre la solution déterministe et stochastique à un instant donné

4
ESTIMATION DE LA PROBABILITÉ QUE $R_\infty > K$

Pourquoi ?

L'estimation de la probabilité $\mathbb{P}(R_\infty > K)$ permet d'évaluer le risque que l'épidémie touche une proportion critique de la population avant son extinction. Cette probabilité est particulièrement utile pour la planification à long terme, notamment en matière de vaccination, de politiques de confinement ou de gestion des ressources hospitalières. Elle donne une idée de la charge sanitaire totale anticipée.

Pour estimer cette probabilité, nous avons appliqué trois méthodes principales :

- **Monte Carlo naïf** : notée **MC** dans nos figures et tableaux.
- **Méthodes d'échantillonnage préférentiel (Importance Sampling)** : notées **IS**. Ces méthodes consistent à modifier la loi sous laquelle les trajectoires sont simulées afin d'accroître la fréquence de l'événement rare (le rendre typique), puis à corriger le biais par un poids d'importance. Deux versions sont considérées :
  - *Version discrète* :
    - Avec optimisation des paramètres via un algorithme d'entropie, notée $\mathbf{IS_{CEdiscret}}$.
    - Utilisant les résultats déterministes (comme l'équation de R_∞), notée $\mathbf{IS_{discret}}$.
  - *Version continue* :
    - Avec optimisation entropique, notée $\mathbf{IS_{CEcontinue}}$.
    - Basée sur les résultats déterministes, notée $\mathbf{IS_{continue}}$.
- **Méthode IBPS (Interacting Branching Particle System)** : une méthode de type splitting, combinant sélection et mutation pour concentrer la simulation sur les trajectoires menant à l'événement rare. Notée **IPS**.

Chaque méthode fera l'objet d'une présentation détaillée afin d'expliciter les principes sous-jacents et les choix effectués. Nous procéderons ensuite à une comparaison de leurs performances respectives, en nous appuyant sur des critères quantitatifs pour évaluer leur efficacité.

4.1 Formulation du problème

Notre objectif est d'estimer la probabilité qu'une épidémie dépasse un seuil critique K :

$$P(R(\infty) > K) \tag{4}$$

où K est choisi proche de la valeur déterministe $R_{\text{det}}(\infty)$, ce qui en fait un événement rare dans le modèle stochastique.

4.2 Méthode de Monte Carlo standard

Principe de la méthode

La première méthode d'estimation que nous considérons est une approche classique de type Monte Carlo.
L'idée consiste à simuler N trajectoires épidémiques indépendantes et à compter combien d'entre elles aboutissent à une valeur finale $R_\infty^{(k)}$ supérieure à un seuil fixé $K = R_{\infty,\text{th}} + \epsilon$, où $R_{\infty,\text{th}}$ est la valeur prédite par le modèle déterministe.
L'estimateur de la probabilité recherchée s'écrit :

$$\hat{\theta}_N = \frac{1}{N} \sum_{k=1}^{N} \mathbf{1}_{\{R_\infty^{(k)} > K\}}$$

où $R_\infty^{(k)}$ est le nombre total d'individus infectés à la fin de la k-ième simulation (i.e. lorsque $I^{(k)}(t) = 0$).
D'après la loi des grands nombres, on a :

$$\hat{\theta}_N \longrightarrow \mathbb{P}(R_\infty > K) \quad \text{lorsque } N \to \infty.$$

Pour quantifier la qualité de l'estimation, on utilise le théorème central limite. Lorsque $p = \mathbb{P}(R_\infty > K)$, on a :

$$\sqrt{N}(\hat{\theta}_N - p) \xrightarrow[N\to\infty]{\mathcal{L}} \mathcal{N}(0, p(1-p)).$$

Intervalle de confiance asymptotique à $1 - \alpha$:

$$\left[\hat{\theta}_N - z_{1-\frac{\alpha}{2}} \cdot \sqrt{\frac{\hat{\theta}_N(1-\hat{\theta}_N)}{N}}, \quad \hat{\theta}_N + z_{1-\frac{\alpha}{2}} \cdot \sqrt{\frac{\hat{\theta}_N(1-\hat{\theta}_N)}{N}}\right],$$

où $z_{1-\frac{\alpha}{2}}$ est le quantile de la loi normale standard.

Ainsi, plus p est petit, plus : l'intervalle de confiance est large, ,le nombre de simulations nécessaires est grand, et la convergence est lente.

$\Rightarrow$ **Les méthodes qui suivent cherchent à surmonter les limites de Monte Carlo standard.**

4.3 Échantillonnage préférentiel (Importance Sampling)

L'idée de l'échantillonnage d'importance est de procéder à une méthode de Monte-Carlo en changeant la loi de probabilité sous laquelle on simule.

On cherche à rendre l'événement *typique*, c'est-à-dire à simuler selon une nouvelle loi de probabilité $\mathbb{P}_{\text{new}}$ pour laquelle

$$\mathbb{P}_{\text{new}}(R_\infty > \text{Seuil})$$

est d'ordre 1 (non rare).

Pour corriger le biais introduit par ce changement, on fait apparaître la vraisemblance dans l'estimateur, selon la relation :

$$\mathbb{P}(R_\infty > \text{Seuil}) = \mathbb{E}\left[\mathbf{1}_{\{R_\infty > \text{Seuil}\}}\right] = \mathbb{E}_{\text{new}}\left[\frac{d\mathbb{P}}{d\mathbb{P}_{\text{new}}}\mathbf{1}_{\{R_\infty > \text{Seuil}\}}\right].$$

Estimateur Monte-Carlo sous la nouvelle loi

] On estime la quantité ci-dessus par la méthode de Monte-Carlo standard en tirant n réalisations $R_\infty^{(k)}$ selon la loi $\mathbb{P}_{\text{new}}$ et en pondérant par la vraisemblance $\phi^{(k)}$:

$$\hat{\theta}_n = \frac{1}{n}\sum_{k=1}^{n} \phi^{(k)}\, \mathbf{1}_{\{R_\infty^{(k)} > \text{Seuil}\}},$$

où $\phi^{(k)} = \frac{d\mathbb{P}}{d\mathbb{P}_{\text{new}}}(R_\infty^{(k)})$ est le poids d'importance associé à la trajectoire simulée.

$\Rightarrow$ **la qualité de l'échantillonnage d'importance dépend fortement du choix de la loi alternative $\mathbb{P}_{\text{new}}$ qui doit minimiser la variance des poids pondérés.**

Dans notre contexte d'épidémie, le changement de loi se fait en modifiant les paramètres du modèle stochastique, par exemple en choisissant de nouveaux paramètres β_{new} et γ_{new} pour le taux d'infection et de récupération lors des simulations.

$\Rightarrow$ **Nous allons présenter quatre méthodes d'échantillonnage préférentiel (importance sampling) : une version continue issue de la littérature, et de version discrète que nous avons proposée. Pour chaque version, les paramètres seront ajustés selon deux approches distinctes : une méthode théorique basé sur le modèle déterministe et une méthode optimisée par *cross-entropy*.**

posons $\phi = \frac{d\mathbb{P}}{d\mathbb{P}_{\text{new}}}$ et commençons par le cas discret.

Version disrète

Nous adoptons une approche discrète fondée sur une version naïve mais motivée : le fait que la variable R_∞ , représentant la fraction totale de rétablis à la fin de l'épidémie, dépend uniquement de l'état final du système, et non du détail temporel de sa trajectoire. Cette observation suggère que l'on peut négliger l'échelle temporelle continue pour se concentrer sur la dynamique de la chaîne de transmission.

En effet, dans le modèle SIR stochastique en temps continu, les transitions (infection ou guérison) se produisent à des instants aléatoires, régis par des lois exponentielles de paramètres $\beta\frac{S(t)I(t)}{N}$ et $\gamma I(t)$. Cela signifie que l'on peut identifier une suite de *temps d'arrêt* $(T_n)_{n\geq 0}$, définis récursivement par :

$$T_n = \inf\{t > T_{n-1} : \text{un événement (infection ou guérison) a lieu i.e une horloge a sonné}\},$$

avec $T_0 = 0$. Ces temps correspondent aux instants où le système change d'état.

À chaque temps T_n, on observe l'état du système $(S_n, I_n, R_n) = (S(T_n), I(T_n), R(T_n))$. Cette suite forme un processus à temps discret. Comme chaque T_n est un temps d'arrêt et que la dynamique du processus dépend uniquement de l'état courant, (S_n, I_n, R_n) hérite de la propriété de Markov du processus continu d'origine.

Ainsi, cette discrétisation repose naturellement sur la dynamique propre du modèle stochastique, sans nécessiter de grille de temps arbitraire. Elle permet non seulement de simuler efficacement les trajectoires du processus, mais également d'estimer des quantités asymptotiques. Par exemple, la variable R_n à un temps t_n de la fin de l'épidémie suffisamment grand fournit une approximation de R_∞, et la probabilité $\mathbb{P}(R_n > K)$ converge vers $\mathbb{P}(R_\infty > K)$ presque sûrement.

Enfin, si l'on souhaite reconstruire des trajectoires continues, on peut recalculé les instants de basculement T_n par des exponentielles indépendants et les interpoler dans notre système discret $(S_n, I_n, R_n) = (S(T_n), I(T_n), R(T_n))$.

Ainsi, on peut modéliser chaque transition d'infection comme un succès d'une variable de Bernoulli, et chaque transition de guérison comme un échec. Si l'on observe p infections (succès) et q guérisons (échecs), alors le poids ϕ s'exprime comme le produit des rapports des probabilités de ces succès et échecs sous la loi modifiée par rapport à la loi originale,

$$\phi = \prod_i \frac{\beta_{\text{new}} \cdot \frac{I^i \cdot S^i}{N} + \gamma_{\text{new}} \cdot I^i}{\beta \cdot \frac{I^i \cdot S^i}{N} + \gamma \cdot I^i} \left(\frac{\beta}{\beta_{\text{new}}}\right)^p \cdot \left(\frac{\gamma}{\gamma_{\text{new}}}\right)^q$$

Version continue

Pour le modèle en temps continu, on trouve dans [5] :

$$\phi = \exp\left(-\int_0^T (\beta - \beta_{\text{new}})\frac{S(t)I(t)}{N}\,dt - \int_0^T (\gamma - \gamma_{\text{new}})I(t)\,dt + \log\left(\frac{\beta}{\beta_{\text{new}}}\right) \cdot \text{p} + \log\left(\frac{\gamma}{\gamma_{\text{new}}}\right) \cdot \text{q}\right)$$

avec $p =$ nombre d'infection et $q =$ nombre des rétablies.

La détermination des paramètres optimaux

$(\beta_{\text{new}}, \gamma_{\text{new}})$ sont critiques pour l'efficacité de l'échantillonnage préférentiel.

- #### Utilisation de la théorie du modèle déterministe

Pour guider ce choix, on peut s'appuyer sur la dynamique du modèle SIR déterministe.

On se rappelle que dans le cadre du modèle SIR déterministe, le nombre total de personnes retirées (infectées puis guéries ou mortes) à la fin de l'épidémie, noté R_∞, satisfait l'équation implicite :

$$R_\infty = N\left[1 - \exp\left(-R_0 \frac{R_\infty}{N}\right)\right]$$

où $R_0 = \frac{\beta}{\gamma}$ est le nombre de reproduction de base.

L'idée est alors la suivante : si l'on souhaite que, sous la nouvelle mesure de probabilité, la proportion de récupérés à la fin soit proche du seuil K (c'est-à-dire que cet événement devienne typique), on peut inverser cette relation pour trouver un R_0^{new} tel que :

$$R_\infty = K$$

En d'autres termes, on choisit un nouveau R_0^{new} (et donc un nouveau rapport $\beta_{\text{new}}/\gamma_{\text{new}}$) qui rend K solution de l'équation ci-dessus. Une fois R_0^{new} fixé, on peut choisir γ_{new} par exemple fixé (proche du γ initial) puis en déduire $\beta_{\text{new}} = R_0^{\text{new}}/\gamma_{\text{new}}$.

- Algorithme de division par entropie croisée (Cross-Entropy)

L'algorithme de division par entropie croisée (Cross-Entropy) permet d'optimiser ces paramètres de manière itérative. (Voir [5])

Algorithm 1 Optimisation adaptative des paramètres d'importance sampling

---

Initialisation : $(\beta_{\text{new}}, \gamma_{\text{new}}) \leftarrow (\beta, \gamma)$ Pour$k = 1$ **à** K Générer M trajectoires avec les paramètres actuels $(\beta_{\text{new}}, \gamma_{\text{new}})$ Sélectionner les trajectoires *élites* telles que $R_\infty^{(i)} >$ Seuil Calculer les poids normalisés :

$$w_i = \frac{\phi_i}{\sum_j \phi_j}$$

Mettre à jour les paramètres par maximum de vraisemblance pondéré :

$$\beta_{\text{new}} \leftarrow \frac{\sum_i w_i \cdot n_{\text{inf},i}}{\sum_i w_i \cdot \int_0^\infty \frac{S_i(t) I_i(t)}{N}\, dt}$$

$$\gamma_{\text{new}} \leftarrow \frac{\sum_i w_i \cdot n_{\text{rec},i}}{\sum_i w_i \cdot \int_0^\infty I_i(t)\, dt}$$

Estimation finale de la probabilité avec les paramètres optimaux :

$$\hat{P}(\mathcal{A}) = \frac{1}{M_{\text{final}}} \sum_{i=1}^{M_{\text{final}}} \mathbf{1}_{\mathcal{A}}(X_i) \cdot \phi_i$$

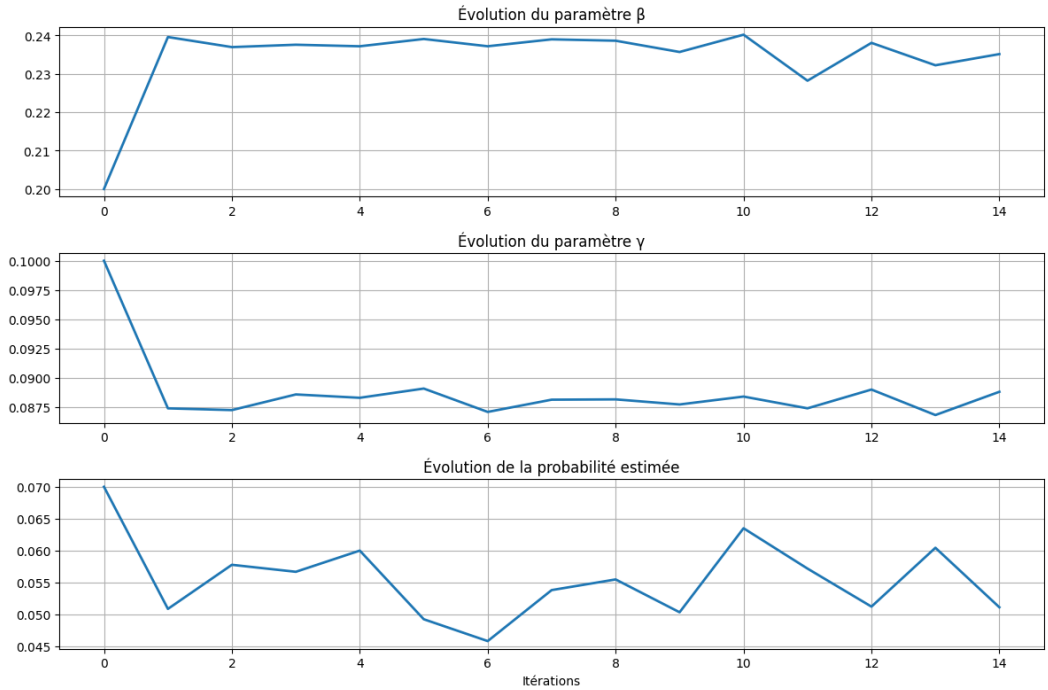

FIGURE 13 – Evolution des paramètre β et γ et la probabilité au fil des itérations

On remarque que la méthode cross-entropy permet bien de trouver dans moins de deux itérations les paramètres adéquats, même si la probabilité estimée (de l'ordre de 0.055) varie avec un écart de 0.015.

4.4 Méthode de splitting

La méthode des systèmes de particules en interaction et de branchement (IBPS) utilise une séquence de niveaux intermédiaires pour estimer progressivement la probabilité d'intérêt.

Soit $K_1 < K_2 < \cdots < K_n = K$ une séquence de seuils. Nous pouvons décomposer :

$$P(R(\infty) > K) = P(R(\infty) > K_1) \cdot \prod_{i=1}^{n-1} P(R(\infty) > K_{i+1} | R(\infty) > K_i)$$

- **Implémentation : Systèmes de particules en interaction (IBPS)**

Soit $x^{(i,k)}$ la trajectoire de la i-ème particule à la k-ème itération. L'algorithme IBPS génère un système de particules de Markov $(x^{(i,k)})_{i=1,\ldots,N\text{particule}}^{k=0,\ldots,K}$ dont la loi d'évolution est définie par :

1. **Initialisation** : Les particules $X^{(i,0)} i = 1, \ldots, N\text{part}$ sont des copies indépendantes du processus original.
2. **Sélection** : À chaque étape k, on identifie l'ensemble $\mathcal{I}_k$ des indices des particules satisfaisant A_k. La proportion $p_k = \frac{|\mathcal{I}_k|}{N_{\text{part}}}$ estime $\mathbb{P}(A_k | A_{k-1})$.
3. **Mutation** : Les particules ne satisfaisant pas A_k sont remplacées par des copies des particules satisfaisant A_k, jusqu'au temps de premier passage au seuil r_k, puis évoluent indépendamment selon la dynamique originale.

4.5 Analyse comparative des méthodes

- Estimation d'une probabilité de 10^{-1}

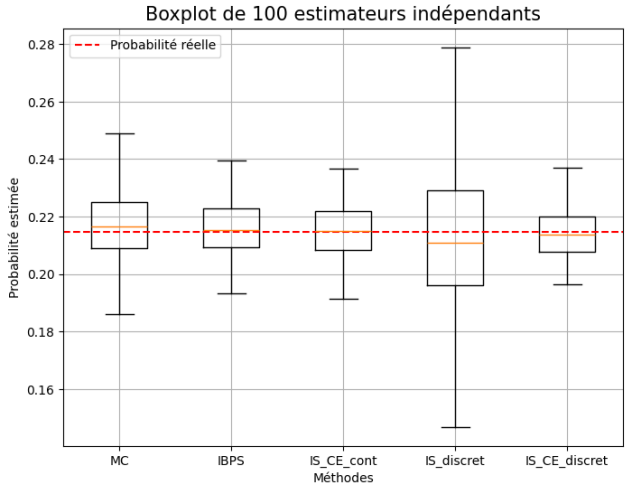

Figure 14 – Boxplots des estimateurs de la probabilité par les différentes méthodes.

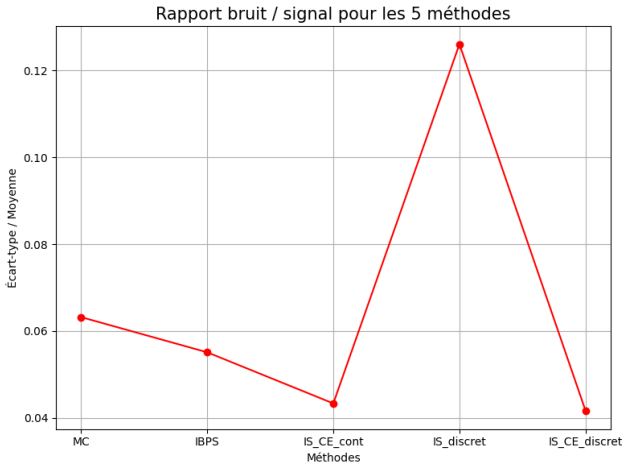

Figure 15 – Rapport bruit/signal ($\frac{\text{écart-type}}{\text{moyenne}}$) pour chaque méthode.

⇒ On observe que, pour une probabilité de l'ordre de 10^{-1}, les trois méthodes donnent de bons résultats. Cependant, la méthode d'*Importance Sampling* discrète présente un écart-type élevé, qui est nettement réduit lorsqu'on utilise l'*IS* discrète couplée à la méthode de *Cross-Entropy* (CE) pour le choix des paramètres.

- Estimation d'une probabilité de 10^{-4}

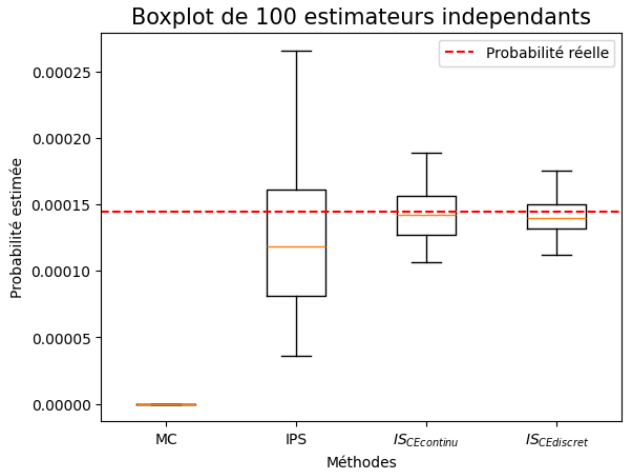

Figure 16 – Boxplots des estimateurs de la probabilité par les différentes méthodes.

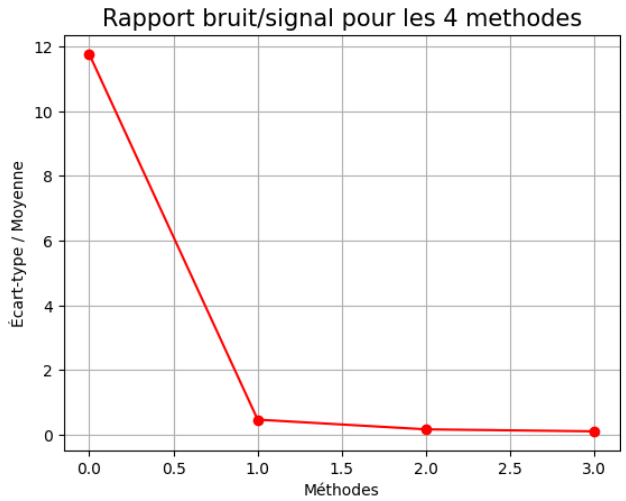

Figure 17 – Rapport bruit/signal ($\frac{\text{écart-type}}{\text{moyenne}}$) pour chaque méthode.

⇒ On remarque que, pour des événements rares, la méthode *IPS* perd en efficacité, tandis que l'*Importance Sampling* couplé à la méthode de *Cross-Entropy* continue de bien performer.

Cette perte d'efficacité de l'*IPS* peut être expliquée par le choix de niveaux équidistants pour la fonction de score, ce qui n'est pas optimal lorsque les événements deviennent de plus en plus rares. En effet, il serait préférable d'utiliser des niveaux de plus en plus rapprochés à mesure qu'on se rapproche de l'événement rare, afin de mieux guider la sélection des trajectoires et concentrer les ressources de simulation là où elles sont les plus utiles.

⇒ Pour une probabilité de l'ordre de 10^{-4}, la méthode de Monte Carlo naïf (**MC**) devient inefficace : le nombre de trajectoires nécessaires pour obtenir une estimation fiable devient prohibitif. En revanche, les méthodes fondées sur l'échantillonnage préférentiel, surtout l'IS discret performent très bien lorsqu'on choisi nos paramètres avec le CE.

- Estimation d'une probabilité de 10^{-8}

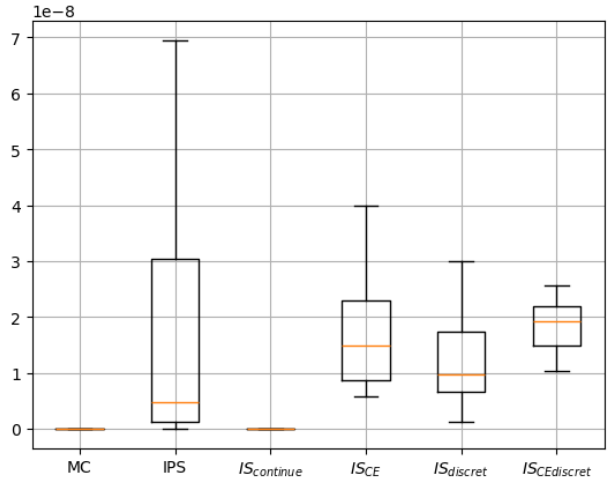

Figure 18 – Boxplots des estimateurs de la probabilité par les différentes méthodes. On présente sur l'axe des abcissses la probabilité estimé et sur l'axe des ordonnées les différentes méthodes testées.

⇒ Quand on dépasse les probabilités de l'ordre de 10^{-8}, l'IPS perd son efficacité et on ne peut compter que sur l'IS.

⇒ Une fois encore, la version discrète de l'*importance sampling* combinée à l'algorithme de *cross-entropy* s'avère être la plus performante.

- Conclusion

Méthode la plus performante. Parmi l'ensemble des méthodes testées, la version discrète de l'Importance Sampling couplée à l'algorithme de *Cross-Entropy* s'est révélée être la plus performante. Elle a permis d'obtenir les estimations les plus précises, même dans le cadre de probabilités très faibles.

Importance de la modélisation et du choix des paramètres. Cette étude nous a également permis de prendre conscience que l'efficacité des méthodes de simulation repose avant tout sur la qualité de la modélisation et le choix judicieux des paramètres. L'idée de discrétiser le processus et d'optimiser les paramètres via l'algorithme de *Cross-Entropy* s'est révélée particulièrement efficace. À l'inverse, dans les méthodes de type Splitting, l'utilisation de niveaux équidistants,

bien que simple à implémenter, nous a semblé moins adaptée et pourrait être améliorée par des stratégies de sélection plus fines et adaptées à la dynamique du processus.

5
ÉTUDE DES ÉVENEMENT RARES : ESTIMATION DE LA PROBABILITÉ $P(I_{\max} > K)$

Pourquoi ?

La probabilité $\mathbb{P}(I_{\max} > K)$ quantifie le risque que le nombre d'infectés atteigne à un moment donné un seuil critique K, dépassant par exemple les capacités hospitalières. Ce type d'estimation est essentiel pour anticiper des situations de saturation du système de santé, ajuster la répartition des lits, et mettre en place des mesures de mitigation à court terme.

Pour réaliser cette estimation, on refait les mêmes simulations et les mêmes méthodes (Monte-Carlo - Importance sampling combiné avec le cross entropy version continue - et la méthode de splitting) mais cette fois-ci pour étudier l'événement $\mathbb{P}(I_{\max} > K)$

5.1 Comparaison des méthodes

5.1.1 • probabilité de l'ordre de 10^{-1}

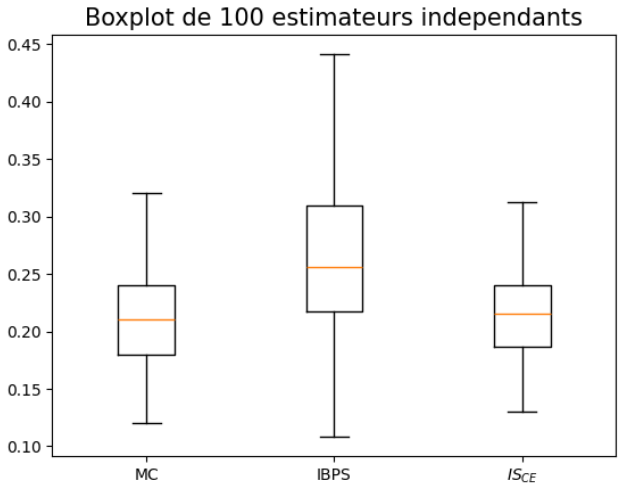

Figure 19 – Boxplot de 100 estimateurs indépendants (I_max > 30 ; $\beta = 0.2$; $\gamma = 0.1$). On présente sur l'axe des abcissses la probabilité estimé et sur l'axe des ordonnées les différentes méthodes testées

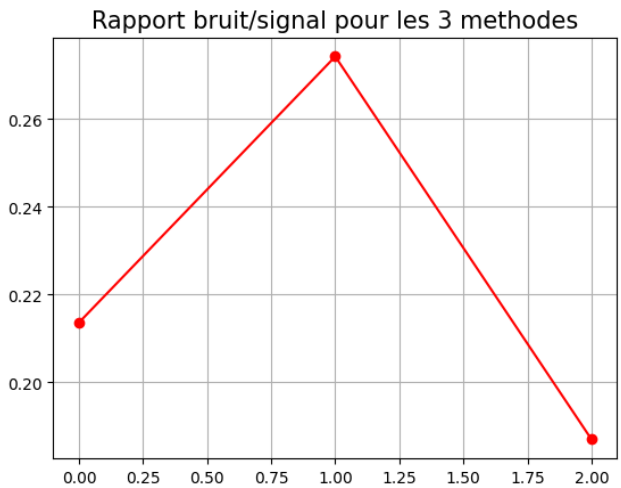

Figure 20 – Rapport bruit/signal pour les 3 méthodes (I_max > 30). On présente sur l'axe des abcissses le rapport bruit/ signal et sur l'axe des ordonnées les différentes méthodes testées dans le même ordre que dans le boxplot à coté

⇒Pour des probabilités grandes, les méthodes marchent bien mais par contre l'IBPS possède un grand écart-type.

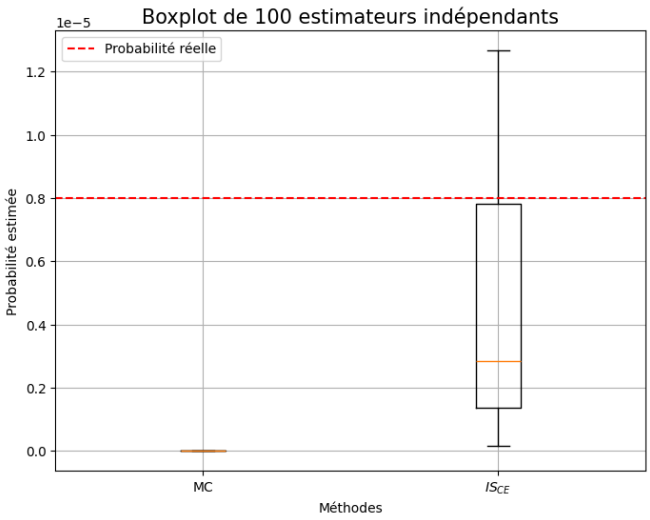

FIGURE 21 – Boxplot de 100 estimateurs indépendants

5.1.2 • PROBABILITÉ DE L'ORDRE DE 10^{-5}

⇒ Lorsqu'on atteint l'échelle de 10^{-5}, même l'**Importance Sampling** continu montre ses limites, avec un écart de l'ordre de 3.5×10^{-6} par rapport à la probabilité réelle. C'est précisément dans ce contexte que notre idée de discrétiser le processus, pour estimer la probabilité que $R_\infty > K$ (voir section précédente), s'est révélée cruciale. Elle a permis une amélioration notable des performances de l'**Importance Sampling** optimisé par **Cross-Entropy** (**IS-CE**), notamment pour des événements extrêmement rares.

6
EXTENSION DU MODÈLE SIR : LE MODÈLE SEIR

Le modèle **SEIR** est une extension naturelle du modèle SIR qui introduit une phase d'incubation avant qu'un individu infecté devienne contagieux. Cela permet une meilleure modélisation des maladies à incubation non négligeable (comme la grippe, le COVID-19, etc.).

6.1 COMPARTIMENTS DU MODÈLE SEIR

— **S (Susceptible)** : individus sains susceptibles d'être infectés.

— **E (Exposed)** : individus infectés mais non encore contagieux (période d'incubation).

— **I (Infectious)** : individus infectés et contagieux.

— **R (Recovered/Removed)** : individus guéris (ou décédés), ne participent plus à la transmission.

Les paramètres du modèle sont :

— β : taux de transmission (contact susceptible-infecté).

— σ : taux de passage de E à I, soit l'inverse de la durée moyenne d'incubation.

— γ : taux de guérison (ou de sortie du compartiment I).

6.2 Modèle déterministe

Dans sa version déterministe, le modèle SEIR est décrit par le système d'équations différentielles ordinaires suivant :

$$\begin{aligned}
\frac{dS}{dt} &= -\beta \frac{SI}{N} \\
\frac{dE}{dt} &= \beta \frac{SI}{N} - \sigma E \\
\frac{dI}{dt} &= \sigma E - \gamma I \\
\frac{dR}{dt} &= \gamma I
\end{aligned}$$

Ce système est typiquement résolu numériquement, avec des conditions initiales $S(0), E(0), I(0), R(0)$.

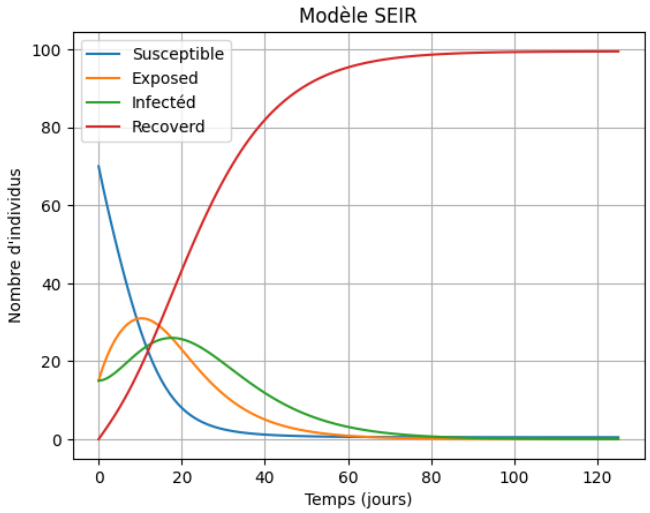

Figure 22 – Modèle SEIR

6.3 Modèle stochastique

Lorsque la taille de la population est relativement faible ou lorsqu'on veut modéliser l'aléa inhérent aux interactions, on peut utiliser un modèle SEIR stochastique basé sur une chaîne de Markov à temps continu :

$$(S(t), E(t), I(t), R(t))_{t \geq 0}$$

avec transitions :

$$\begin{aligned}
&(S, E, I, R) \to (S-1, E+1, I, R) && \text{à un taux } \beta \cdot \frac{S \cdot I}{N} \\
&(S, E, I, R) \to (S, E-1, I+1, R) && \text{à un taux } \sigma \cdot E \\
&(S, E, I, R) \to (S, E, I-1, R+1) && \text{à un taux } \gamma \cdot I
\end{aligned}$$

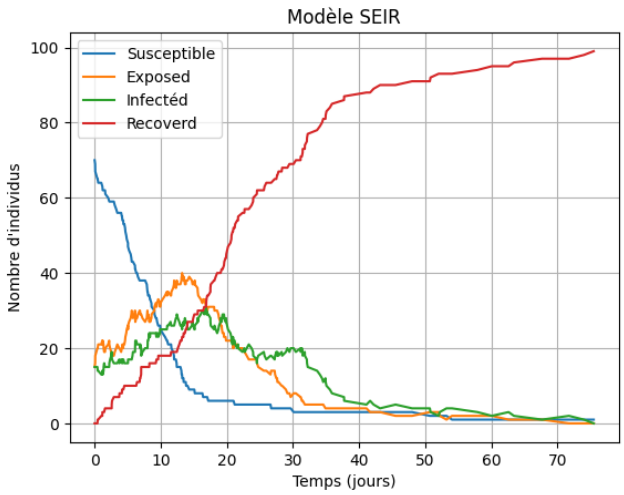

FIGURE 23 – N = 100

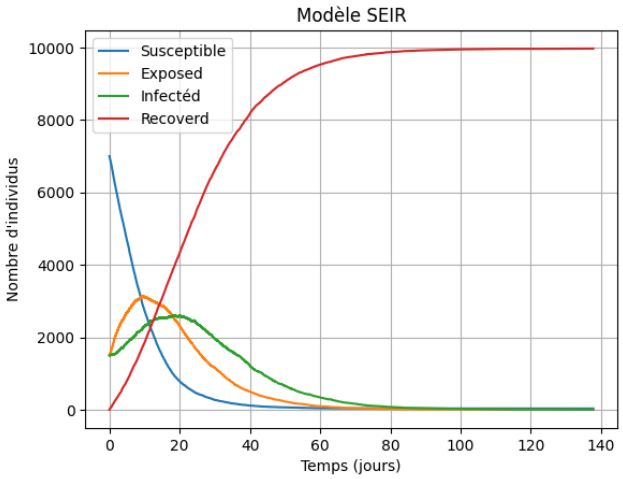

FIGURE 24 – N = 10000

6.4 Intérêt de l'ajout du compartiment E

Bien que σ n'intervienne pas dans le calcul du nombre de reproduction de base $R_0 = \frac{\beta}{\gamma}$, il influence fortement la dynamique temporelle de l'épidémie :

- Plus σ est faible (incubation longue), plus l'épidémie démarre lentement.
- La courbe des infections est décalée dans le temps, ce qui peut retarder le pic sans nécessairement en diminuer l'intensité.
- Cela peut donner un temps de réponse précieux pour les politiques de santé publique.

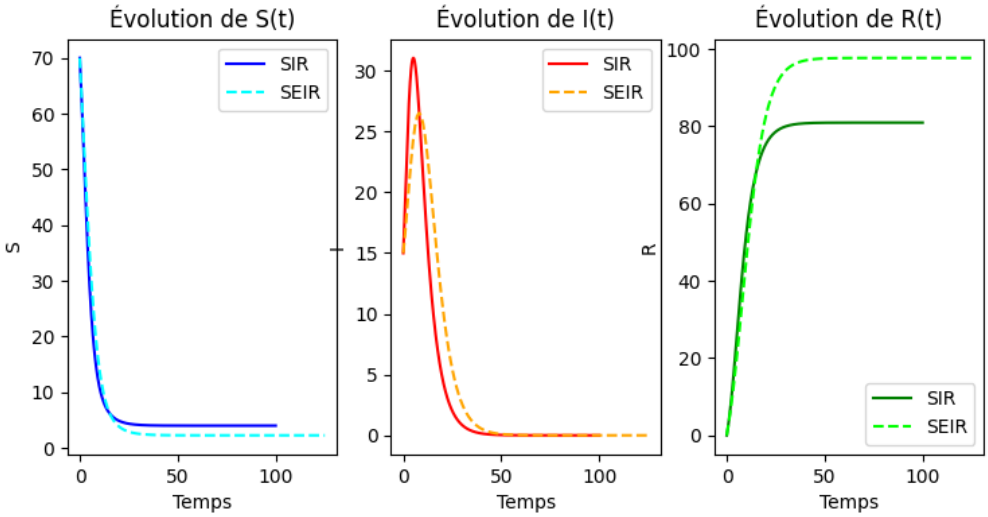

7 GRAPHES

Le modèle SIR présenté précédemment est de type « champ moyen », c'est-à-dire qu'il suppose un contact homogène entre tous les individus. Pour intégrer la géographie, on modélise désormais la population par un graphe $G = (V, E)$, où chaque sommet $v \in V$ représente un individu, et

chaque arête $u, v \in E$ indique un lien de contact direct. On définit alors une dynamique de Markov sur l'état de chaque sommet (S,I,R) :

- **Un sommet infecté (I) passe en état immunisé (R) à un taux ρ.**
- **Un sommet sain (S) devient infecté (I) à un taux k, où k est le nombre de ses voisins infectés.**

Remarque :
Considérons un graphe complet (c'est-à-dire que tous les sommets sont connectés entre eux), représentant une population de taille N. On suppose que la dynamique de propagation suit un processus stochastique, avec les paramètres suivants :

$$\rho = \gamma \quad \text{et} \quad \alpha = \frac{\beta}{N}$$

- Chaque individu infecté guérit (et devient immunisé) avec un taux $\rho = \gamma$. Ainsi, selon le theorème, l'effectif de la population immunisée augmente de 1 avec un taux global $\rho \cdot I(t)$, où $I(t)$ désigne le nombre d'individus infectés à l'instant t.
- Chaque individu sain devient infecté avec un taux $\alpha \cdot k$, où k est le nombre de ses voisins infectés. Dans un graphe complet, tous les individus sont voisins entre eux, donc chaque individu sain a exactement $I(t)$ voisins infectés. On a alors :

  $$\alpha \cdot k = \frac{\beta}{N} \cdot I(t)$$

  Comme il y a $S(t)$ individus sains à l'instant t, le taux global d'infection est donc :

  $$\frac{\beta}{n} \cdot I(t) \cdot S(t)$$

Ces deux taux correspondent exactement aux termes présents dans le modèle différentiel SIR :

$$\begin{cases} \frac{dS}{dt} = -\frac{\beta}{N} S(t)I(t) \\ \frac{dI}{dt} = \frac{\beta}{nN} S(t)I(t) - \gamma I(t) \\ \frac{dR}{dt} = \gamma I(t) \end{cases}$$

On retrouve ainsi que le modèle SIR peut être vu comme une approximation moyenne d'un processus stochastique sur un graphe complet. Supposons qu'à chaque instant, chaque individu infecté guérit indépendamment selon une loi exponentielle de paramètre ρ. Alors, l'effectif de la population immunisée augmente de 1 avec un taux total $\rho \cdot I(t)$, où $I(t)$ désigne le nombre d'individus infectés à l'instant t.

7.1 Epidémie sur $\mathbf{Z}$

Figure 25 – État sur un segment de $\mathbb{Z}$

7.1.1 • La loi théorique du nombres d'infectés

Soit I_{gauche} (resp. I_{droite}) le nombre de personnes infectées strictement à gauche (resp. à droite) du site 0, que l'on suppose être le site initialement infecté (hypothèse sans perte de généralité car le problème est spatiallemnt symétrique).

Définissons la quantité suivante :

$$a = \frac{\rho}{\rho + \alpha}$$

où ρ est le taux d'infection et α le taux de guérison.

Au premier événement (transition), trois cas peuvent se produire :

— (S, I, I) : le site à gauche est susceptible, celui au centre est infecté, et celui à droite est infecté.

— (I, I, S) : le site à gauche est infecté, celui au centre est infecté, et celui à droite est susceptible.

— (S, R, S) : le site central guérit (il devient rétabli), et les sites gauche et droit sont susceptibles.

Conditionnellement à cette première transition, les variables I_{gauche} et I_{droite} sont indépendantes. On a donc la décomposition suivante de la probabilité conjointe :

$$\begin{aligned} P(I_{\text{gauche}} = i_{\text{gauche}},\, I_{\text{droite}} = i_{\text{droite}}) = {} & P(I_{\text{gauche}} = i_{\text{gauche}}, I_{\text{droite}} = i_{\text{droite}} \mid \text{SII})P(\text{SII}) \\ & + P(I_{\text{gauche}} = i_{\text{gauche}}, I_{\text{droite}} = i_{\text{droite}} \mid \text{IIS})P(\text{IIS}) \\ & + P(I_{\text{gauche}} = i_{\text{gauche}}, I_{\text{droite}} = i_{\text{droite}} \mid \text{SRS})P(\text{SRS}). \end{aligned}$$

Calcul des contributions :

— Pour le cas **SII** (infection vers la droite) :

$$\begin{aligned} & P(I_{\text{gauche}} = i_{\text{gauche}}, I_{\text{droite}} = i_{\text{droite}} \mid \text{SII})P(\text{SII}) \\ & = \frac{\rho}{2\rho + \alpha} \cdot \mathbf{1}_{\{i_{\text{droite}} \neq 0\}} \cdot a^{i_{\text{droite}} + i_{\text{gauche}} - 1}(1-a)^2 \end{aligned}$$

— Pour le cas **IIS** (infection vers la gauche) :

$$\begin{aligned} & P(I_{\text{gauche}} = i_{\text{gauche}}, I_{\text{droite}} = i_{\text{droite}} \mid \text{IIS})P(\text{IIS}) \\ & = \frac{\rho}{2\rho + \alpha} \cdot \mathbf{1}_{\{i_{\text{gauche}} \neq 0\}} \cdot a^{i_{\text{gauche}} + i_{\text{droite}} - 1}(1-a)^2 \end{aligned}$$

— Pour le cas **SRS** (guérison immédiate, aucun autre infecté) :

$$P(I_{\text{gauche}} = 0, I_{\text{droite}} = 0 \mid \text{SRS})P(\text{SRS}) = \frac{\alpha}{2\rho + \alpha} \cdot \mathbf{1}_{\{i_{\text{gauche}} = 0,\, i_{\text{droite}} = 0\}}$$

Conclusion : En combinant les trois cas, on obtient :

$$P(I_{\text{gauche}} = i_{\text{gauche}}, I_{\text{droite}} = i_{\text{droite}}) = \frac{\rho}{2\rho + \alpha} \cdot a^{i_{\text{gauche}} + i_{\text{droite}} - 1}(1-a)^2 \cdot \Big[\mathbf{1}_{\{i_{\text{gauche}} \neq 0\}} + \mathbf{1}_{\{i_{\text{droite}} \neq 0\}}\Big] + \frac{\alpha}{2\rho + \alpha} \cdot \mathbf{1}_{\{i_{\text{gauche}}}$$

Le nombre total d'infectés est donné par :

$$I = 1 + I_{\text{gauche}} + I_{\text{droite}}.$$

On en déduit, pour tout $n \geq 1$:

$$P(I = n) = \sum_{k=0}^{n-1} P(I_{\text{gauche}} = k,\, I_{\text{droite}} = n - 1 - k).$$

Calcul explicite : En injectant l'expression précédente dans la somme :

$$P(I=n) = \sum_{k=0}^{n-1} \left[\frac{\rho}{2\rho+\alpha} \cdot a^{n-2}(1-a)^2 \cdot \left(\mathbf{1}_{\{k\neq 0\}} + \mathbf{1}_{\{k\neq n-1\}} \right) + \frac{\alpha}{2\rho+\alpha} \cdot \mathbf{1}_{\{k=0,\, n-1=0\}} \right].$$

En simplifiant, on obtient :

Loi nombre total d'infectés I

Loi de I :

$$P(I=n) = \begin{cases} (n-1)\, a^{n-2}(1-a)^2 \cdot \dfrac{2\rho}{2\rho+\alpha} & \text{si } n \geq 2, \\ \dfrac{\alpha}{2\rho+\alpha} & \text{si } n = 1. \end{cases}$$

Espérance du nombre d'infectés :

$$\begin{aligned} \mathbb{E}[I] &= \sum_{n=1}^{\infty} n \cdot P(I=n) \\ &= \sum_{n=1}^{\infty} n \left[(n-1) a^{n-2}(1-a)^2 \cdot \frac{2\rho}{2\rho+\alpha} + \mathbf{1}_{\{n=1\}} \cdot \frac{\alpha}{2\rho+\alpha} \right] \end{aligned}$$

Après simplifications et utilisation de séries géométriques classiques, on obtient :

L'espérance du nombre total d'infectés I

$$\mathbb{E}[I] = \frac{2\rho}{2\rho+\alpha} \cdot \frac{2}{1-x} + \frac{\alpha}{2\rho+\alpha} = \frac{1+4x+4x^2}{1+2x}$$

où $x = \frac{\alpha}{\rho}$.

Forme finale simplifiée :

$$\mathbb{E}[I] = 1 + 2x.$$

7.1.2 • La loi théorique de la durée de l'épidemie

On suppose qu'un unique individu est initialement infecté, prenons sans perte de généralité que cet individu est 0. Pour trouver la loi de T on ponse à conditionner par le premier événement (i.e première transiton). On considère trois événements possibles pour la première transition :

$$\begin{aligned} SRS &: \text{ premier saut est une guérison (taux } \rho), \\ SII &: \text{ premier saut est une infection à droite (taux } \alpha), \\ IIS &: \text{ premier saut est une infection à gauche (taux } \alpha). \end{aligned}$$

Les probabilités sont

$$P(SRS) = \frac{\rho}{2\alpha+\rho}, \quad P(IIS) = P(SII) = \frac{\alpha}{2\alpha+\rho},$$

avec symétrie entre infection à gauche ou à droite. La densité de T se décompose donc en

$$f_T(s) = P(SRS)\, f_{T|SRS}(s) + P(SII)\, f_{T|SII}(s) + P(IIS)\, f_{T|IIS}(s).$$

Cas SRS

Si SRS survient, l'épidémie s'arrête immédiatement au premier saut :

$$T \mid SRS \sim \mathbf{Exp}(2\alpha+\rho), \quad f_{T|SRS}(s) = (2\alpha+\rho)\, e^{-(2\alpha+\rho)s}.$$

D'où :

$$P(SRS)\, f_{T|SRS}(s) = \rho\, e^{-(2\alpha+\rho)s}.$$

Cas SII

Conditionnellement à SII, on a :

$$T = U + M, \quad U \sim \mathbf{Exp}(2\alpha+\rho), \quad V_1, V_2 \sim \mathbf{Exp}(\rho) \text{ i.i.d.}, \quad M = \max(V_1, V_2).$$

On calcule d'abord la densité de M :

$$f_M(m) = 2\rho\, e^{-\rho m} - 2\rho\, e^{-2\rho m}.$$

Par convolution,

$$f_{U+M}(s) = \int_0^s (2\alpha+\rho) e^{-(2\alpha+\rho)u} \Big[2\rho\, e^{-\rho(s-u)} - 2\rho\, e^{-2\rho(s-u)}\Big]\, du = A(s) + B(s),$$

avec (pour $2\alpha \neq \rho$) :

$$A(s) = \frac{2\rho\,(2\alpha+\rho)}{2\alpha}\Big(e^{-\rho s} - e^{-(2\alpha+\rho)s}\Big),$$
$$B(s) = -\frac{2\rho\,(2\alpha+\rho)}{2\alpha-\rho}\Big(e^{-2\rho s} - e^{-(2\alpha+\rho)s}\Big).$$

En multipliant par $2P(SII) = \dfrac{2\alpha}{2\alpha+\rho}$, on obtient

$$2P(SII)\, f_{U+M}(s) = 2\rho\, e^{-\rho s} - \frac{4\alpha\rho}{2\alpha-\rho}\, e^{-2\rho s} + \frac{2\rho^2}{2\alpha-\rho}\, e^{-(2\alpha+\rho)s}.$$

Densité finale pour $2\alpha \neq \rho$

$$\boxed{f_T(s) = 2\rho\, e^{-\rho s} - \frac{4\alpha\rho}{2\alpha-\rho}\, e^{-2\rho s} + \frac{\rho(2\alpha+\rho)}{2\alpha-\rho}\, e^{-(2\alpha+\rho)s}}$$

Cas particulier $\rho = 2\alpha$

En prenant la limite $2\alpha - \rho \to 0$, on obtient

$$\boxed{f_T(s) = 4\alpha\, e^{-2\alpha s} + 2\alpha\Big(-1 - 4\alpha s\Big)\, e^{-4\alpha s}}$$

7.1.3 • Comparaison entre les lois théoriques et la simulation numérique

• Comparaison de la loi de durée et de la distribution du nombre d'infections : cas $\rho = 2\alpha$

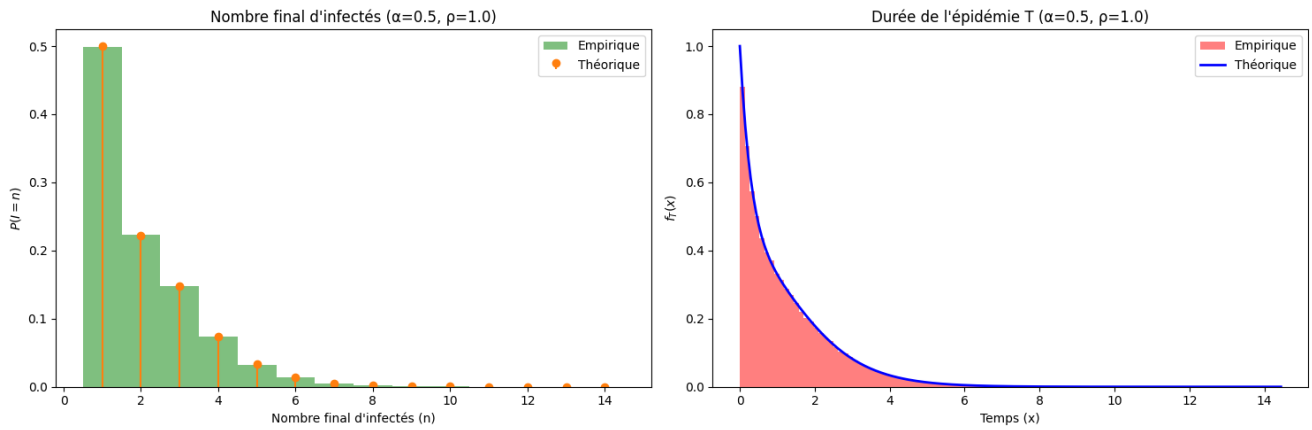

Figure 26 – Distribution de I le nombre d'infecté dinale (figure à gauche) + Densité $f_T(s)$ (figure à droite) : pour $\rho = 2\alpha$

• Comparaison de la loi de durée et de la distribution du nombre d'infections : cas $\rho \neq 2\alpha$

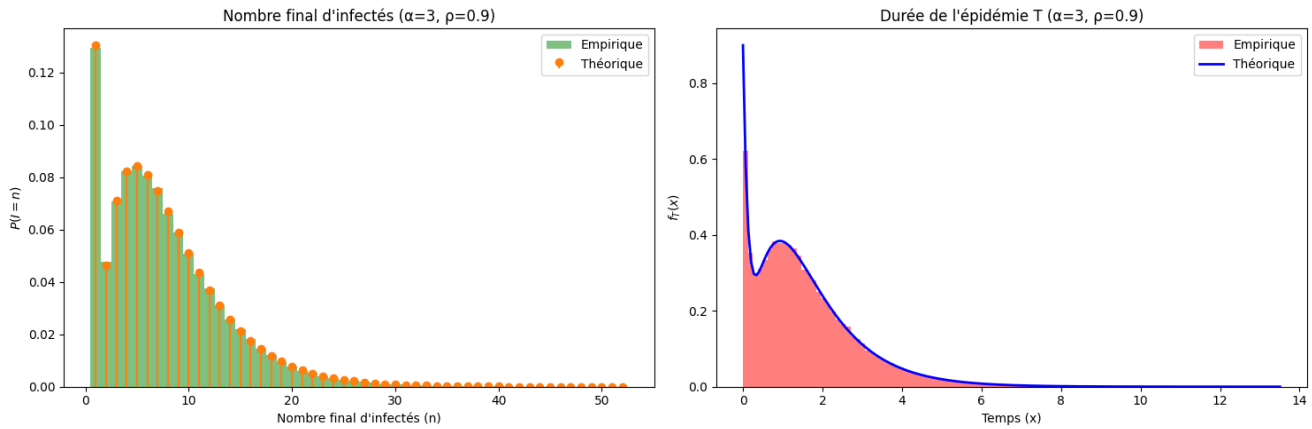

Figure 27 – Distribution de I le nombre d'infecté dinale (figure à gauche)+ Densité $f_T(s)$ (figure à droite) :pour $\rho \neq 2\alpha$

Les deux figures présentent :

— À gauche, la loi théorique de I comparée à sa distribution obtenue par simulation numérique.

— À droite, la loi théorique de T confrontée à sa distribution numérique.

Conclusion :

— Les simulations numériques confirment parfaitement les prédictions théoriques.

— Deux comportements distincts émergent selon que
$\rho = \alpha$ ou non : dans le premier cas, la loi de durée reflète l'équilibre exact entre l'extinction précoce de l'épidémie et sa propagation sur Z, alors que dans le second, l'une de ces issues prédomine.

7.2 Tirage sous la loi de la durée de lépidémie

Dans cette section, nous comparons la distribution théorique de la durée de l'épidémie avec des lois simulées à l'aide de trois méthodes classiques étudiées en cours :

— la simulation par inversion de la fonction de répartition ;

— la simulation par la méthode de rejet ;

— l'algorithme de Metropolis-Hastings, utilisé ici pour simuler la loi conditionnelle de la durée t sachant $T > k$.

⇒ Cette étape permet de valider empiriquement les résultats théoriques vus en cours, en comparant les lois simulées à la loi théorique de la durée de l'épidémie. Par ailleurs, les méthodes présentées ici seront réutilisées ultérieurement dans le cadre de l'AMS (Adaptative multi-level splitting).

7.2.1 • Simulation par inversion de la fonction de répartition

La méthode repose sur l'inversion de la fonction de répartition F de la variable aléatoire $\mathcal{D}$ représentant la durée de l'épidémie. Si Q désigne la fonction quantile associée, on utilise le fait suivant :

Propriété fondamentale d'inversion

Soient F la fonction de répartition d'une variable aléatoire X et Q sa fonction quantile. Si $U \sim \mathcal{U}[0,1]$, alors la variable $Q(U)$ suit la même loi que X.

Nous utilisons donc la relation $\mathcal{D} = Q(U)$ pour simuler des valeurs de la durée de l'épidémie.

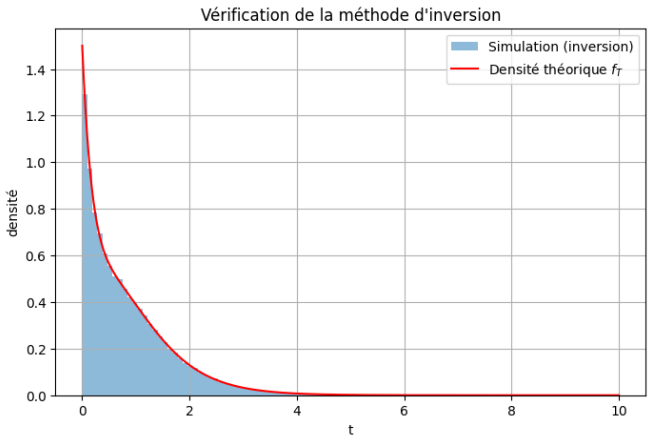

Figure 28 – Simulation de f_T par méthode d'inversion

7.2.2 • Simulation par la méthode de rejet

La méthode de rejet permet de simuler une variable aléatoire à partir d'une densité cible f, à condition de connaître une densité auxiliaire g et une constante $c > 0$ telles que $f(x) \leq cg(x)$ pour presque tout x.

Algorithme de rejet

Soient f et g deux densités sur $\mathbb{R}^d$ vérifiant $\exists c > 0$ tel que $f(x) \leq cg(x)$ pour ν-presque tout x. On simule une variable aléatoire de densité f selon les étapes suivantes :

1. Répéter les étapes suivantes :
   — Simuler $Y_n \sim g$;
   — Simuler $U_n \sim \mathcal{U}[0,1]$;
2. Tant que $cU_n g(Y_n) < f(Y_n)$, rejeter Y_n ;
3. Retourner Y_n dès que l'inégalité est satisfaite.

Cette méthode est particulièrement utile lorsque la densité f est difficile à simuler directement, mais que l'on peut évaluer son expression et qu'on dispose d'une densité g plus simple.

Choix de la densité g et de la constante c pour la méthode de rejet : Nous avons choisi comme densité propositionnelle g une densité exponentielle de paramètre $\lambda > 0$, définie par

$$g(s) = \lambda e^{-\lambda s} \mathbf{1}_{s \geq 0}.$$

Le paramètre λ a été sélectionné en regard de la forme analytique de la densité cible f_T, qui est une combinaison de termes exponentiels décroissants avec des taux ρ, 2ρ, et $2\alpha + \rho$. Pour garantir que g majorera f_T sur $\mathbb{R}^+$, nous avons choisi

$$\lambda = \min\{\rho, 2\rho, 2\alpha + \rho\}.$$

Ce choix assure que la décroissance exponentielle de g est au moins aussi lente que celle de chaque composante de f_T, permettant ainsi de trouver une constante $c > 0$ telle que

$$\forall s \geq 0, \quad f_T(s) \leq c\, g(s).$$

Nous avons estimé numériquement cette constante c en calculant le supremum de $\frac{f_T(s)}{g(s)}$ sur un intervalle suffisamment large, ce qui nous a conduit à la valeur approximative

$$c = 2.$$

Cette constante $c = 2$ garantit la validité de la méthode de rejet en assurant que la densité cible f_T est toujours inférieure à cg, tout en limitant le taux de rejet et donc en optimisant l'efficacité de la simulation.

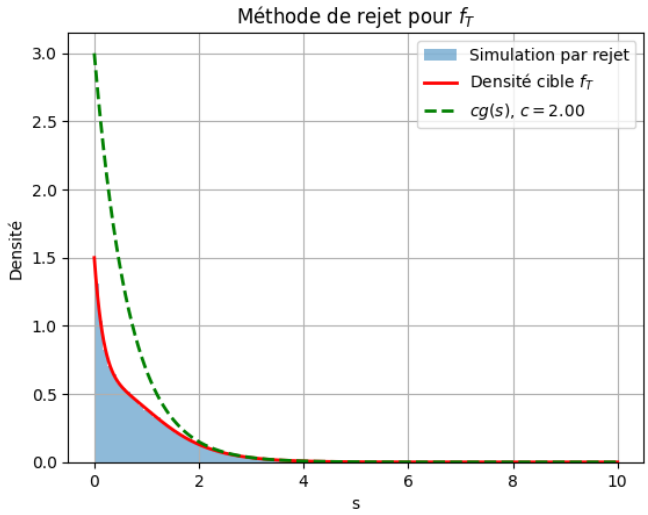

FIGURE 29 – Méthode de rejet pour f_T

7.2.3 • MÉTROPOLIS HASTING POUR LA LOI CONDITIONNELLE DE T SACHANT $T > K$

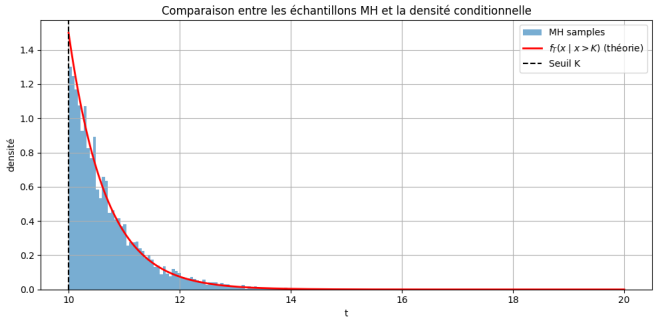

FIGURE 30 – Loi conditionnellle de T sachant $T > K$ par Métropolis Hasting

7.3 ESTIMATION DES PROBABILITÉS DES ÉVÉNEMENTS RARES

PROBABILITÉ QUE $T > K$ EN UTILISANT AMS

Estimer la probabilité que $T > K$ permet d'évaluer le risque qu'une épidémie dure anormalement longtemps. Ce type de quantification est crucial pour la planification sanitaire, la gestion des ressources hospitalières ou la mise en place de politiques publiques.

Pour estimer cette probabilité, nous utiliserons à la fois la méthode de Monte Carlo naïf et l'algorithme de Splitting adaptatif (AMS). Comme la loi exacte de T est connue dans notre modèle simplifié, cela nous permettra de valider les estimations obtenues par simulation en les comparant à la solution théorique.

- Théorie

Algorithm 2 AMS : estimation de $\mathbb{P}(T > q)$

Entrée : n (nombre de particules), q (seuil) **Initialisation :**$X_1, \ldots, X_n \sim f_T$ i.i.d. puisque f_T n'est pas usuelle on a utilisé la méthode de rejet pour simuler les X_i $J \leftarrow 0$ $\min(X_1, \ldots, X_n) \leq q$ $J \leftarrow J + 1$ $L_J \leftarrow \min(X_1, \ldots, X_n)$ $m \leftarrow \arg\min_i X_i$ Rééchantillonner $X_m \sim f_T(T \mid T > L_J)$ (Les autres X_i restent inchangés), pour la probabilité conditionnelle comme présentée dans la section précédente on a utilisé Métropolis-Hasting pour la simuler. **Sortie :** $\hat{p} = \left(1 - \frac{1}{n}\right)^J \approx \mathbb{P}(T > q)$ **Retourner :** $(\hat{p}, J)$

- Résultats

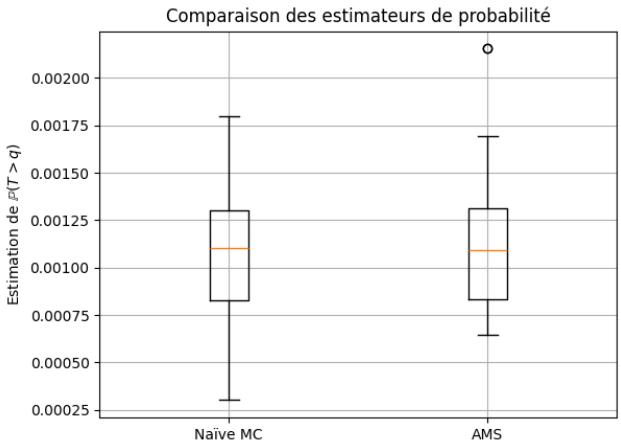

Figure 31 – Probabilité que la durée de l'épidémie dépasse q — régime typique

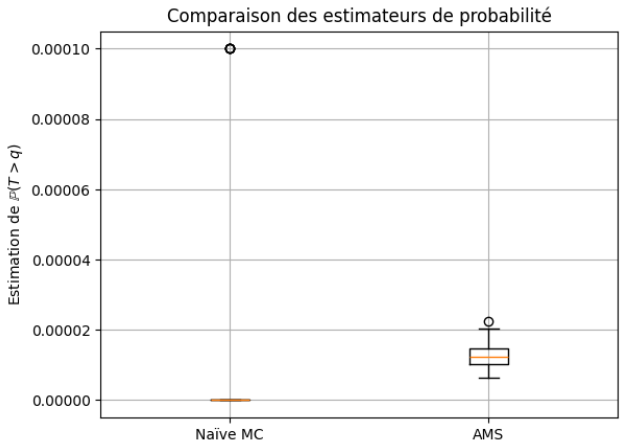

Figure 32 – Probabilité que la durée de l'épidémie dépasse q — régime rare

- Discussion

⇒ Pour des probabilités dans un régime « typique », de l'ordre de 10^{-3}, l'estimateur par Monte Carlo naïf et l'estimateur par importance sampling fournissent des résultats comparables. En effet, avec un nombre de simulations $M = 1000$, la méthode Monte Carlo naïve permet d'obtenir une estimation suffisamment précise pour ce niveau de probabilité.

⇒ En revanche, lorsque la probabilité devient beaucoup plus faible, de l'ordre de 10^{-5}, l'estimateur Monte Carlo naïf ne converge plus assez rapidement pour produire une estimation fiable. Cette lente convergence s'explique par le fait que le nombre de simulations nécessaires pour obtenir une estimation stable est beaucoup plus important, de l'ordre de 10^5 simulations, ce qui est souvent prohibitif en termes de coût computationnel.

⇒ Ainsi, dans ce contexte, l'estimateur par importance sampling s'avère beaucoup plus performant. En ciblant efficacement les événements rares, il permet d'obtenir une estimation précise de la probabilité même avec un nombre de simulations nettement plus faible, rendant cette méthode particulièrement adaptée pour l'estimation des probabilités très faibles.

Les deux figures ci-dessous 33 illustrent la validation de deux résultats théoriques concernant l'importance sampling (AMS) : d'une part, la convergence en loi de la variable J_n vers une loi

de Poisson $\mathcal{P}(-n \ln p)$, et d'autre part, la convergence en distribution de la variable centrée et normalisée $\sqrt{n}(\hat{p}_n - p)$ vers une loi normale $\mathcal{N}(0, -p^2 \ln p)$.

Loi de J_n	**TCL pour $\hat{p}_n$**
$J_n \sim \mathcal{P}(-n \ln p)$	$\sqrt{n}(\hat{p}_n - p) \xrightarrow{d} \mathcal{N}(0, -p^2 \ln p)$

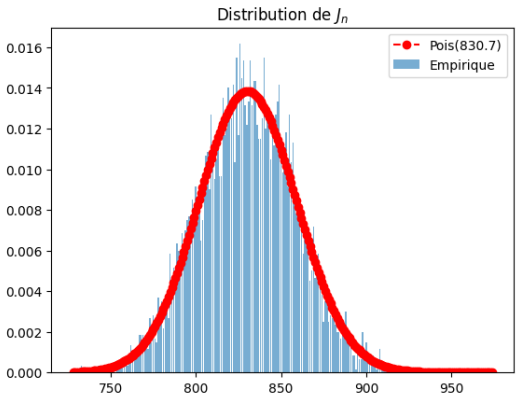

Simulation numérique de la loi de J_n (Poisson)

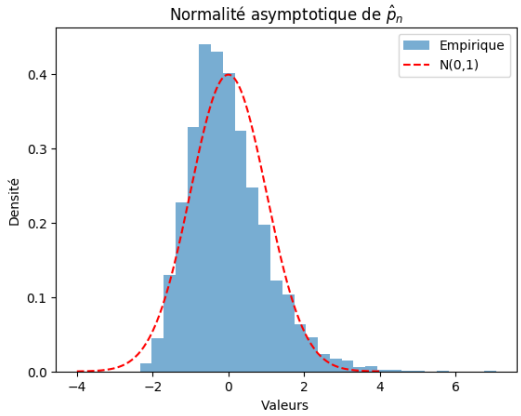

Illustration numérique de la convergence vers la loi normale

FIGURE 33 – Comparaison des résultats théoriques et des simulations numériques pour J_n et $\hat{p}_n$

PROBABILITÉ QUE $I > K$ EN UTILISANT IMPORTANCE SAMPLING

Pour estimer cette probabilité, nous utiliserons à la fois la méthode de Monte Carlo naïf et l'algorithme de Importance sampling (IS). Comme la loi exacte de I est connue dans notre modèle, cela nous permettra de valider les estimations obtenues par simulation en les comparant à la solution théorique.

- THÉORIE

L'idée de l'importance sampling est de modifier la loi de simulation pour suréchantillonner les événements rares, puis de corriger le biais introduit par une pondération.

FORMULATION MATHÉMATIQUE

On souhaite estimer :

$$\mathbb{E}_P[\mathbf{1}_{I>k}] = \int \mathbf{1}_{I>k} \, dP.$$

On introduit une loi de proposition Q et on réécrit :

$$\mathbb{E}_P[\mathbf{1}_{I>k}] = \mathbb{E}_Q\left[\mathbf{1}_{I>k} \cdot \frac{dP}{dQ}\right].$$

(A) Loi théorique $P(I = n)$

La fonction `theoretical_prob_I(n, rho, alpha)` calcule :

$$P(I = n) = \begin{cases} \dfrac{\alpha}{2\rho + \alpha} & \text{si } n = 1, \\ (n-1)\left(\dfrac{\rho}{\rho+\alpha}\right)^{n-2}\left(\dfrac{\alpha}{\rho+\alpha}\right)^{2}\dfrac{2\rho}{2\rho+\alpha} & \text{si } n \geq 2. \end{cases}$$

Où :

— $a = \dfrac{\rho}{\rho + \alpha}$ est la probabilité qu'un individu infectieux guérisse avant de contaminer,

— $1 - a$ est la probabilité qu'il infecte un voisin.

(B) Loi de proposition Q

Pour favoriser les grandes valeurs de I, on choisit :

$$Q(n) = (1 - \tilde{a})\,\tilde{a}^{n-1}, \quad \text{avec } \tilde{a} > a$$

où $\tilde{a}$ est un paramètre choisi pour augmenter artificiellement la fréquence des grandes épidémies.
$\Longrightarrow$ Notre choix de loi Q repose d'abord sur une considération intuitive : la forme de la loi théorique de I évoque une décroissance exponentielle, suggérant une proximité avec une loi géométrique. Cette analogie nous a naturellement conduits à envisager une loi géométrique comme loi de proposition. Pour accentuer artificiellement la fréquence des grandes valeurs de I (celles qui contribuent à l'événement rare $\{I > k\}$), nous avons modifié le paramètre de la loi géométrique afin d'obtenir une décroissance plus lente : c'est l'idée de la géométrique modifiée avec un paramètre $\tilde{a} > a$.

(C) Estimateur IS

Pour chaque échantillon $n \sim Q$, on calcule :

$$w(n) = \frac{P(n)}{Q(n)},$$

où $P(n)$ est donné par la fonction `theoretical_prob_I` dans le notebook. L'estimateur final est :

$$\widehat{P(I > k)} = \frac{1}{N}\sum_{i=1}^{N} \mathbf{1}_{n_i > k} \cdot w(n_i).$$

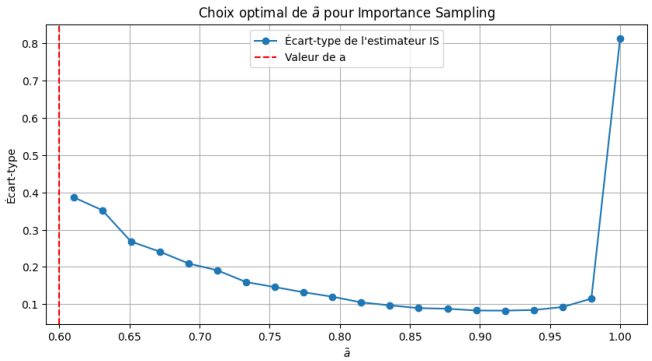

Figure 34 – Choix de la valeur de $\tilde{a}$ qui minimise la variance (ie. écart type)

Dans la figure ci-dessus (Figure 34), nous avons tracé l'écart-type de l'estimateur pour différentes valeurs de $\tilde{a}$, avec $\tilde{a}$ compris entre a et 1, c'est-à-dire $\tilde{a} > a$ et $\tilde{a} < 1$. Cette figure nous donne une bonne idée du choix optimal de $\tilde{a}$.

Pour notre étude, nous avons opté pour $\tilde{a} = 0{,}93$, qui est supérieur à la valeur initiale $a = 0{,}6$.

- Résultats

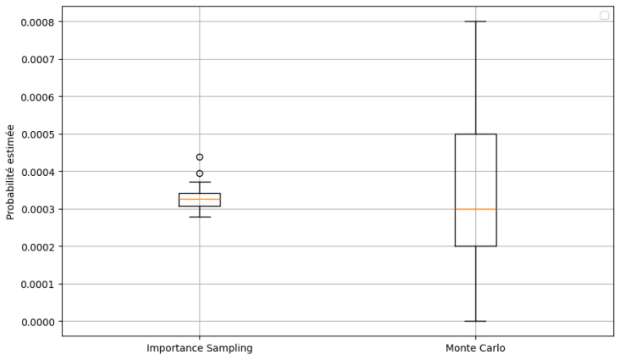

Figure 35 – Probabilité que le nombre d'infection final de l'épidémie dépasse q — probabilité d'ordre 10^{-3}

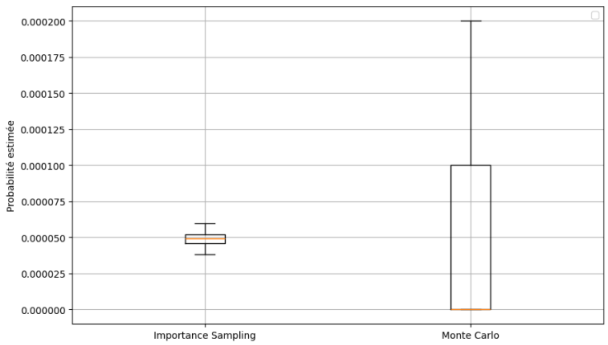

Figure 36 – Probabilité que le nombre d'infection final de l'épidémie dépasse q — probabilité d'ordre 10^{-4}

- Discussion

Méthode	**Simulation 1**	**Simulation 2**
Théorique	0.000048	0.000326
Importance Sampling	0.000048	0.000320
Monte Carlo	0.000042	0.000278

Table 1 – Comparaison des estimations de $P(I > k)$ selon Is et MC naif

Les résultats présentés dans le tableau 1 montrent clairement que la méthode d'importance sampling devient beaucoup plus intéressante pour l'estimation des probabilités rares. En effet, même pour des probabilités d'ordre 10^{-4}, l'estimateur Monte Carlo naïf est moins efficace que l'estimateur par importance sampling. Ceci se traduit par une erreur relative plus faible et un intervalle de confiance plus étroit pour l'importance sampling.

Les figures associées confirment cette observation, illustrant que l'importance sampling permet d'obtenir des estimations plus précises et stables, surtout lorsque l'événement d'intérêt est rare.

7.4 Epidémie sur un arbre régulier

Calcul du taux critique α_c : On considère l'épidémie SIR sur un arbre d-régulier, où chaque individu infecté peut infecter chacun de ses d fils avant de guérir.

1. **Modélisation de la descendance.**

— Temps jusqu'à infection d'un fils : exponentiel de paramètre α.

— Temps de guérison : exponentiel de paramètre ρ.

Par propriétés des lois exponentielles indépendantes, la probabilité que l'infection précède la guérison est

$$p \;=\; \mathbb{P}[\text{infection avant guérison}] \;=\; \frac{\alpha}{\alpha+\rho}.$$

L'espérance du nombre d'enfants infectés est

$$\mathbb{E}(\mu) \;=\; d\,p \;=\; d\,\frac{\alpha}{\alpha+\rho}.$$

3. **Critère d'extinction.** Pour un processus de Galton–Watson dont la descendance a pour moyenne $m = \mathbb{E}(\mu)$:

$$\begin{cases} m \le 1 & \Longrightarrow \text{ extinction presque sûre,} \\ m > 1 & \Longrightarrow \text{ survie avec probabilité } > 0. \end{cases}$$

4. **Détermination de α_c.** La phase critique se produit quand $m = 1$. On résout donc

$$d\,\frac{\alpha_c}{\alpha_c+\rho} \;=\; 1 \quad\Longrightarrow\quad d\,\alpha_c \;=\; \alpha_c+\rho \quad\Longrightarrow\quad \alpha_c\,(d-1) \;=\; \rho \quad\Longrightarrow\quad \boxed{\alpha_c \;=\; \frac{\rho}{d-1}.}$$

Ainsi, dès que

$$\alpha \begin{cases} < \;\alpha_c & \text{(sous-critique : extinction p.s.),} \\ > \;\alpha_c & \text{(sur-critique : survie possible).} \end{cases}$$

□

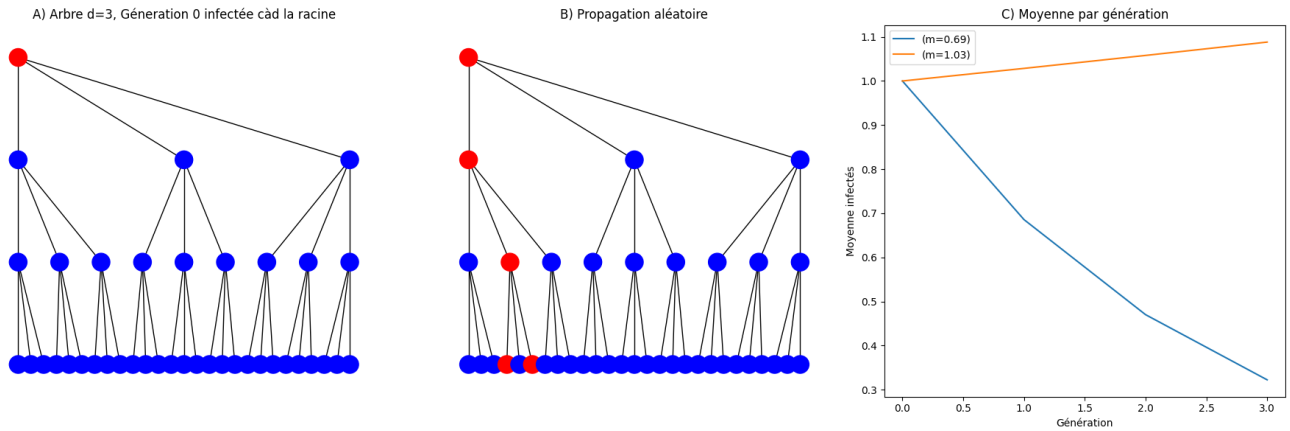

Dans la figure **??**.C, on observe deux courbes représentant le nombre moyen d'individus infectés en fonction de la génération : la courbe décroissante ($m < 1$; Régime sous-critique) illustre la disparition progressive de l'épidémie, tandis que la courbe croissante ($m > 1$; Régime sur-critique) montre une croissance exponentielle conforme au critère de phase illustré par la théorie.

8
CONCLUSION ET PERSPECTIVES

Ce projet nous a permis de prendre conscience de l'importance des outils de simulation dans la compréhension et l'évaluation des risques liés à la propagation de maladies infectieuses. La modélisation stochastique des épidémies illustre de manière concrète comment les mathématiques peuvent éclairer des enjeux de santé publique, en aidant à anticiper des scénarios critiques tels que la survenue d'une épidémie majeure. Les épidémies, à l'instar d'autres phénomènes aléatoires comme les catastrophes naturelles ou les sinistres en assurance, soulignent la nécessité de disposer de méthodes fiables pour estimer des événements rares.

Dans le cadre de notre étude, nous avons exploré plusieurs approches présentées au cours, en combinant des modèles déterministes, stochastiques, ainsi que des représentations géométriques sur graphe pour modéliser la dynamique des épidémies. Si les méthodes de Monte Carlo classiques se sont montrées peu efficaces pour estimer des événements très rares, les techniques d'échantillonnage préférentiel (Importance Sampling) et l'approche AMS ont permis d'obtenir des estimations bien plus précises et efficaces. Ces méthodes se sont révélées particulièrement pertinentes pour capturer des dynamiques peu probables mais critiques, telles que la survenue d'une épidémie de grande ampleur malgré un faible taux initial de transmission.

Par ailleurs, cette étude nous a permis de prendre conscience que l'efficacité de ces méthodes repose avant tout sur la qualité de la modélisation et le choix judicieux des paramètres. Cela s'est particulièrement illustré dans le cas de l'estimation de la probabilité $\mathbb{P}(R_\infty > K)$, où l'idée de discrétiser le processus et d'optimiser les paramètres à l'aide de l'algorithme de *Cross-Entropy* a significativement amélioré les performances de l'Importance Sampling. Cette expérience souligne à quel point une bonne adaptation du modèle et des techniques d'optimisation peut faire toute la différence dans la simulation d'événements rares.

Pour approfondir cette étude, il aurait été pertinent d'explorer d'autres aspects de la modélisation stochastique des épidémies. En effet, notre analyse s'est principalement concentrée sur l'estimation de probabilités du type $\mathbb{P}(X > K)$, correspondant à des scénarios critiques tels qu'un dépassement de seuil épidémique. Cependant, il aurait également été intéressant d'étudier les probabilités complémentaires, comme $\mathbb{P}(X < K)$, qui peuvent refléter des situations de contrôle efficace de l'épidémie ou des scénarios de sous-propagation. Ces perspectives pourraient enrichir la compréhension globale des dynamiques épidémiques et guider des décisions plus équilibrées en matière de santé publique.

RÉFÉRENCES

[1] Wikipedia. *Modèles compartimentaux en épidémiologie.*
https://en.wikipedia.org/wiki/Compartmental_models_in_epidemiology

[2] Sellke, T. (1982). *On the asymptotic distribution of the size of a stochastic epidemic.* Technical Report No. 17, Stanford University.
https://statistics.stanford.edu/research/asymptotic-distribution-size-stochastic-epi

[3] Andersson, H. & Britton, T. (2000). *Stochastic Epidemic Models and Their Statistical Analysis.* Lecture Notes in Statistics, Vol. 151. Springer-Verlag, New York.
https://staff.math.su.se/tom.britton/newmain.pdf

[4] Hethcote, H. W. (2000). *The Mathematics of Infectious Diseases.* SIAM Review, Vol. 42, No. 4.
http://www.maths.usyd.edu.au/u/marym/populations/hethcote.pdf

[5] Clémençon, S., Cousien, A., Dávila Felipe, M., & Tran, V. C. (2015). *On computer-intensive simulation and estimation methods for rare event analysis in epidemic models.* Stat. Med., Vol. 34, No. 28.
https://hal.archives-ouvertes.fr/hal-00854458/document